GPNB_v1 使用手册

Genomic Prediction Network Builder

安装 操作教程 参数参考与核查说明

软件版本 1.0.0

本手册面向具有遗传育种背景期望快速和便捷开展深度学习基因组预测模型构建的研究人员。

目录

1 软件简介与适用范围 4
2 安装、启动与更新 4
2.1 找到程序根目录 4
2.2 首次安装 5
2.3 启动与再次启动 5
2.4 修复、移动与更新 6
2.5 显式指定环境 6
3 最短完整流程 合成数据演示 6
3.1 训练并查看结果 6
3.2 预测新的合成个体 11
4 准备数据并检查匹配 12
4.1 填写数据与项目 13
4.2 方式一 PLINK BED/BIM/FAM 13
4.3 方式二 数值矩阵 13
4.4 表型文件与 ID 14
4.5 训练前检查 14
4.6 原始矩阵导出与训练预处理 15
5 构建预测网络 15
5.1 先选择输入，再编辑网络 15
5.2 用层卡片编辑网络 16
5.3 顺序网络与分支网络 16
5.4 模板与组件范围 16
5.5 明确选择论文架构与参数 17
6 选择评估协议 18
7 设置训练参数 18
7.1 损失与优化器高级设置 19
8 配置训练内预处理 20
9 搜索少量超参数组合 20
10 检查、启动与监控训练 21
11 分别训练多个性状，或联合输出 22
12 可选的分阶段训练 22
13 为新个体训练最终模型 22
14 查看、导出和解释结果 23

14.1 先确认评价范围 23
14.2 选择保存内容 24
14.3 CSV 字段参考 25
15 预测新个体 25
16 常见问题与故障排查 26
17 可选 用命令复现小型示例 28
18 网络组件与全部注册参数 29
18.1 理解布局与端口 29
18.2 常用参数含义 29
18.3 全连接、激活与 Dropout 30
18.4 布局、切片与位点分组 31
18.5 一维卷积与池化 32
18.6 归一化 33
18.7 循环层 33
18.8 基因型嵌入、token 与掩码 34
18.9 注意力与序列混合 35
18.10 分支、门控与组合块 35
18.11 位点图与个体参考 36
18.12 显式二维网格 37
18.13 自相关与分解 38
18.14 辅助重建 39
18.15 额外的形状与解释规则 39

1 软件简介与适用范围

本教程对应当前 `GPNB_v1` 程序，内部版本号为 `1.0.0`。图示和演示均使用合成个体。软件是面向连续性状基因组预测的 Windows 桌面工具：选择数据、配置 PyTorch 回归网络、按照明确的数据划分评估模型，再将冻结模型应用于待预测个体。主要面向具有遗传育种背景、希望通过界面完成分析的研究人员。

第一次使用时，建议依次阅读：安装 → 合成数据快速开始 → 准备自己的数据 → 配置网络与训练 → 解释和导出结果。命令行示例为可选内容，主要流程不要求编程。

• PLINK BED/BIM/FAM 和明确配置的二倍体硬判定矩阵输入；按个体标识匹配表型。

• 89 个网络组件、30 个通用模板及 8 个带来源说明的论文架构适配，包含输入与维度检查。

• 在训练数据内拟合填补、标准化和可选位点筛选；可配置额外数值输入、核特征和明确的图协议。

• 固定训练/验证/测试划分、五折与十折交叉验证、留一个体；内部参数搜索和早停。

• 多性状分别训练，或明确配置的联合多目标回归。

• Pearson、RMSE、MAE 及其他诊断指标；逐个体预测、图表、CSV 和离线 HTML 报告。

• 冻结模型包、完整实验导出，以及可在预测完成后评分的新个体预测。

当前已实现 PLINK 与明确编码的硬判定矩阵输入、按 ID 匹配表型、可编辑网络、在训练数据内拟合预处理、固定划分与交叉验证、参数搜索、各性状独立训练及联合多目标回归、结果报告、冻结模型保存和新个体预测。下文说明各组件与协议的适用条件，并非任意组合都可以互换。

软件不是通用 VCF 转换器、系谱分析软件、分类工具，也不会自动给出育种值可靠性。使用标记预测出的表型不因此自动成为估计育种值。若研究目的为跨群体或跨环境预测，需要相应的评价设计；随机划分个体不能证明这种外推能力。论文架构预设是有来源说明的适配实现，不代表已经复现作者论文中的预测准确性。

2 安装、启动与更新

2.1 找到程序根目录

本教程所称“程序根目录”，是同时包含 `pyproject.toml`、`Setup_GPNB_v1.cmd`、`Start_GPNB_v1.cmd`、`src` 和 `requirements` 的文件夹。请保持这些文件在一起。收到 `GPNB_v1.zip` 后，先完整解压到具有写入权限的文件夹，不要直接在压缩包内运行程序。无需自行安装另一套 Python，也无需手动管理 Python 环境。

除特别标注外，本文命令均在**程序根目录打开的 PowerShell** 中执行，不是 Bash 命令。可以先在文件资源管理器打开程序文件夹，再在该位置打开终端并选择 PowerShell 标签页。

要求	当前安装器的实际行为
操作系统	Windows x64（AMD64）。随包安装器不支持 macOS、Linux、Windows ARM64 或 WSL。
安装终端	Windows PowerShell；CMD 入口调用系统 `powershell.exe`。
Python	安装器配置本地 CPython 3.12.11；程序元数据要求 Python 3.12。
CPU 环境	PyTorch 2.7.1+cpu；安装前至少有 8 GiB 可用磁盘空间。

要求	当前安装器的实际行为
GPU 环境	`cuda` 使用 PyTorch 2.7.1+cu126，`cuda118` 使用 2.7.1+cu118。至少有 25 GiB 可用空间，并需要兼容的 NVIDIA 显卡与驱动。
其他主要依赖	NumPy 1.26.4、PySide6 6.8.3、bed-reader 1.0.6、Matplotlib 3.10.1、psutil 7.0.0。
联网要求	首次安装下载固定版本的 Python 和依赖；安装成功后的正常启动可以离线完成。

上述磁盘值是安装器的检查阈值，不是真实实验所需内存、显存或存储空间的估计。安装器不修改系统 Python 或 NVIDIA 驱动。模型规模、标记数、参考矩阵和数据副本还会消耗额外资源。

2.2 首次安装

运行最小演示时，先安装 CPU 环境：

PowerShell

```
.\Setup_GPNB_v1_CPU.cmd -Language zh_CN
```

若希望交互选择环境：

PowerShell

```
.\Setup_GPNB_v1.cmd -Language zh_CN
```

根据提示选择 `cpu`、`cuda` 或 `cuda118`。也可以直接指定，例如：

PowerShell

```
.\Setup_GPNB_v1.cmd -Profile cuda -Language zh_CN
```

安装器会创建 `runtime`、`cache`、`tmp` 和 `logs`，下载并校验安装组件，建立隔离环境，按锁文件核对依赖哈希，安装本地程序，并检查依赖导入、BED 读取、CPU/GPU 小型计算与 Qt。检查时可能短暂出现一个自动关闭的窗口。成功标志为 **`[5/5] 配置完成。双击 Start_GPNB_v1.cmd 启动；日志和诊断已保存。`**对应环境会生成 `gpnb-ready.json`，`runtime/active-profile.json` 记录当前环境。检查失败不会被标记为安装就绪。

推荐环境依据已安装驱动信息判断；当前保守的 Windows 驱动阈值为：`cuda` 560.76，`cuda118` 522.06。达到推荐阈值不等于显卡一定兼容，仍须通过实际计算检查。GPU 环境不可用时可选择 CPU。本次文档工作未测量首次联网下载耗时。

2.3 启动与再次启动

PowerShell

```
.\Start_GPNB_v1.cmd -Language zh_CN
```

此入口使用最近一次配置成功的环境。明确使用已安装的 CPU 环境：

PowerShell

```
.\Start_GPNB_v1_CPU.cmd -Language zh_CN
```

不带参数双击入口时默认为中文。窗口顶部也可以切换中文和 English。英文启动使用 `-Language en_US`，每次启动都需指定；启动器不会读取安装时保存的语言。CPU 快捷入口只选择运行环境，不会改写已打开项目的训练设备，请核对界面中的“计算设备”和“预测设备”。

仅对于 Windows **命令提示符（CMD）**，在程序根目录的等价中文启动命令为：

CMD

```
Start_GPNB_v1.cmd -Language zh_CN
```

2.4 修复、移动与更新

安装失败时，查看最新 `logs/setup-*.log`、相应 `.status.json` 和已经产生的 `logs/doctor-*.json`，按具体错误恢复网络或释放空间，再重复原安装命令。修复已安装但损坏的 CPU 环境：

PowerShell

```
.\Setup_GPNB_v1.cmd -Profile cpu -Repair -Language zh_CN
```

修复其他环境时，将 `cpu` 改成对应名称；先关闭软件工作进程。只有所需安装器、Python 运行时和依赖缓存完整时，安装命令才可以增加 `-Offline`；ZIP 本身不是包含全部依赖的离线安装包。启动命令不接受 `-Offline`。

当前没有应用内自动更新器，包内也没有已确认的公开更新地址。作者提供新版后，将其解压到另一个可写目录，执行该副本的安装入口，再打开项目副本。保留旧项目、完整实验目录和模型包；在新版中重新检查数据、划分与设置后再开展实验。不要合并不同副本的虚拟环境。移动已安装目录后，应从新位置重新运行安装器，因为启动检查会核对环境所属路径。尚未发布版本的兼容性不能预先保证。

2.5 显式指定环境

下列命令补充独立安装说明中列出的具体写法。请在解压后的 GPNB_v1 应用文件夹中打开 **PowerShell**，不要在 ZIP 内运行；应用文件夹应包含 `Setup_GPNB_v1.cmd`、`Start_GPNB_v1.cmd` 和 `pyproject.toml`。

除 CPU 快捷入口外，也可通过通用安装入口显式选择 CPU：

PowerShell

```
.\Setup_GPNB_v1.cmd -Profile cpu -Language zh_CN
```

安装 CUDA 11.8 环境的明确命令为：

PowerShell

```
.\Setup_GPNB_v1.cmd -Profile cuda118 -Language zh_CN
```

启动已安装的 CPU 环境，也可显式指定环境名称：

PowerShell

```
.\Start_GPNB_v1.cmd -Profile cpu -Language zh_CN
```

这些命令使用已有安装入口，不增加新的安装模式。GPU 环境仍需兼容的 NVIDIA 显卡和驱动；CPU 启动选择只决定使用哪个运行环境，不会自动修改已保存项目中的训练设备设置。

3 最短完整流程 合成数据演示

随附示例包含 65 个合成个体、32 个合成标记和名为 `trait` 的连续性状，其中两个表型值故意设为缺失；另外提供 8 个独立模拟的待预测个体。不包含真实研究数据或私人个体资料。

为了缩短演示，示例明确设置 CPU、3 个 epoch、早停耐心值 3、批大小 16、线程数 1。这些是**演示覆盖值**，不是新建项目默认值，也不是科研推荐参数。普通新建项目对应默认值为 100 个 epoch、耐心值 20、批大小 64、线程数 2。示例没有启用参数搜索或交叉验证。

3.1 训练并查看结果

1. 用上述 CPU 命令启动。界面有“数据与项目”“网络构建”“训练设置”“运行监视”“训练结果”“新个体预测”六个页面。

2. 点击顶部“打开”，选择 `examples/quickstart/project.json`。项目名称为 **Synthetic quick start**，数据集名称为 `synthetic_quickstart`，性状为 `trait`。项目中的相对路径以项目文件所在目录为基准，打开时会解析。

3. 点击“另存为”，保存一个新的工作项目，例如 `projects/quickstart-demo.json`。如需另选输出位置，用“运行输出目录”的选择按钮指定可写目录。示例默认输出根目录解析为程序下的 `runs`。

4. 在“数据与项目”向下滚动，点击“检查数据与匹配”。应看到 65 个基因型个体、32 个标记、63 个有限且成功匹配的表型、2 个缺失表型。这个界面检查不统计全部基因型缺失单元格，完整导入时才执行该扫描。

5. 打开“网络构建”，保留 `Linear 64 → ReLU → Linear 16 → ReLU → Linear 1` 网络。本示例无需修改网络层。

6. 打开“训练设置”，确认“固定划分”、CPU 和上述 3 轮演示参数。点击“生成 / 预览实际划分”。本示例实际得到 **44 个训练个体、10 个验证个体、9 个测试个体**，两个缺失表型不参加本次单性状拟合。

7. 向下滚动，点击“运行前检查”，等待检查清单通过。该过程含有限规模的数值探针，不是已经完成的评价实验。检查有效后，“开始训练”才可用；修改相关数据或设置后需要重新检查。

8. 点击“开始训练”，在“运行监视”查看进度。成功后进入“训练结果”。GUI 会创建 `runs/experiments/<时间戳>_<唯一后缀>` 下的新目录，与后文 CLI 使用的固定示例目录名称不同。

9. 在“3. 预测结果”中保留“外样本测试 / OOF”。本次固定划分显示 9 个保留测试个体，并不是合并交叉验证结果。查看观测—预测图、个体误差和训练/验证曲线。

10. 在“4. 保存与应用”选择“保存位置”，点击“导出结果”保存图片、CSV 与 HTML，或点击“保存模型”生成冻结预测包。各操作都会创建各自的唯一输出目录。“打开结果目录”可定位当前显示的实验。

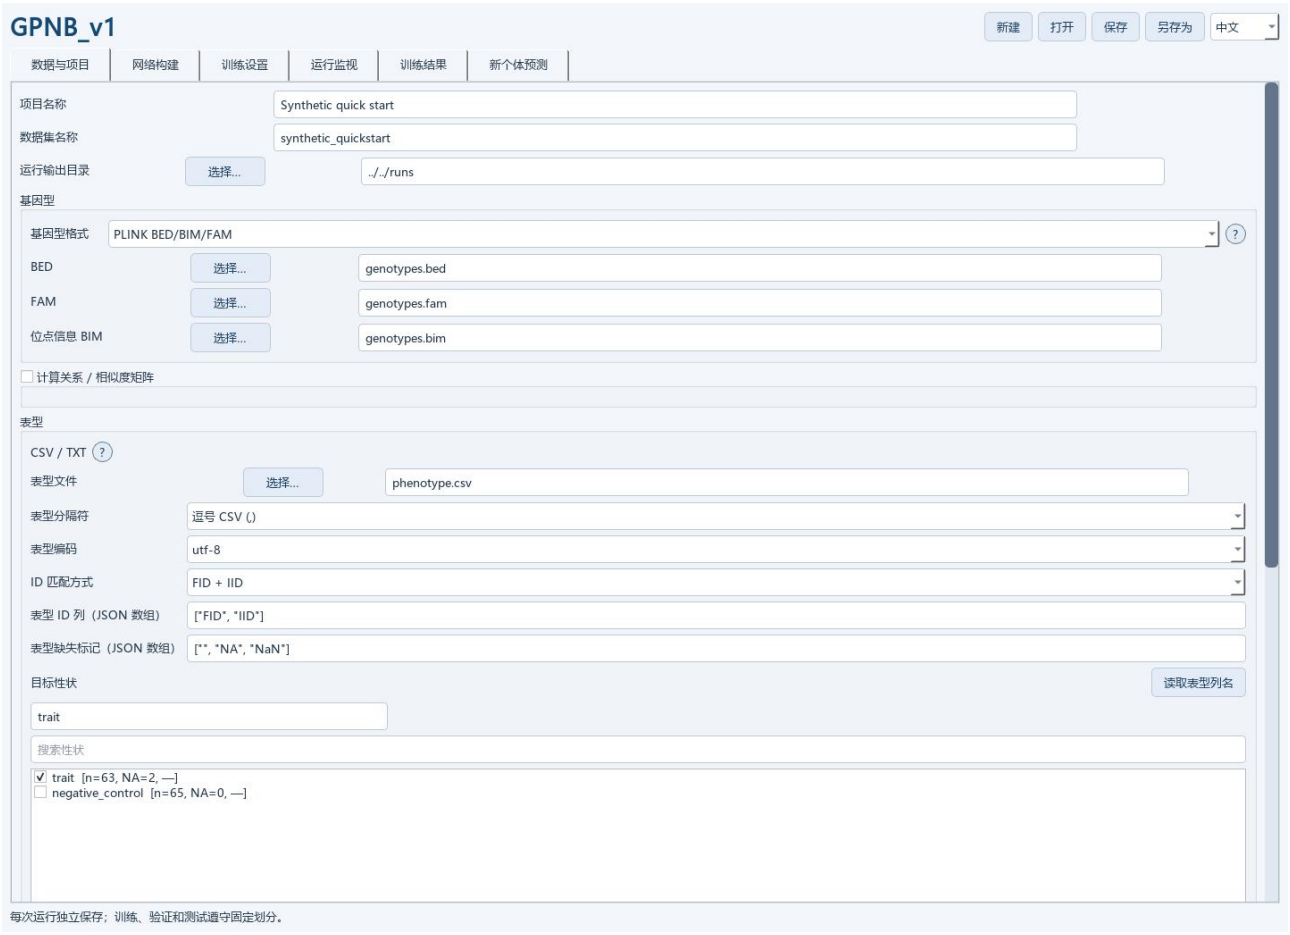


图 1 合成输入的数据与项目页面



图 2 数据检查与样本匹配结果

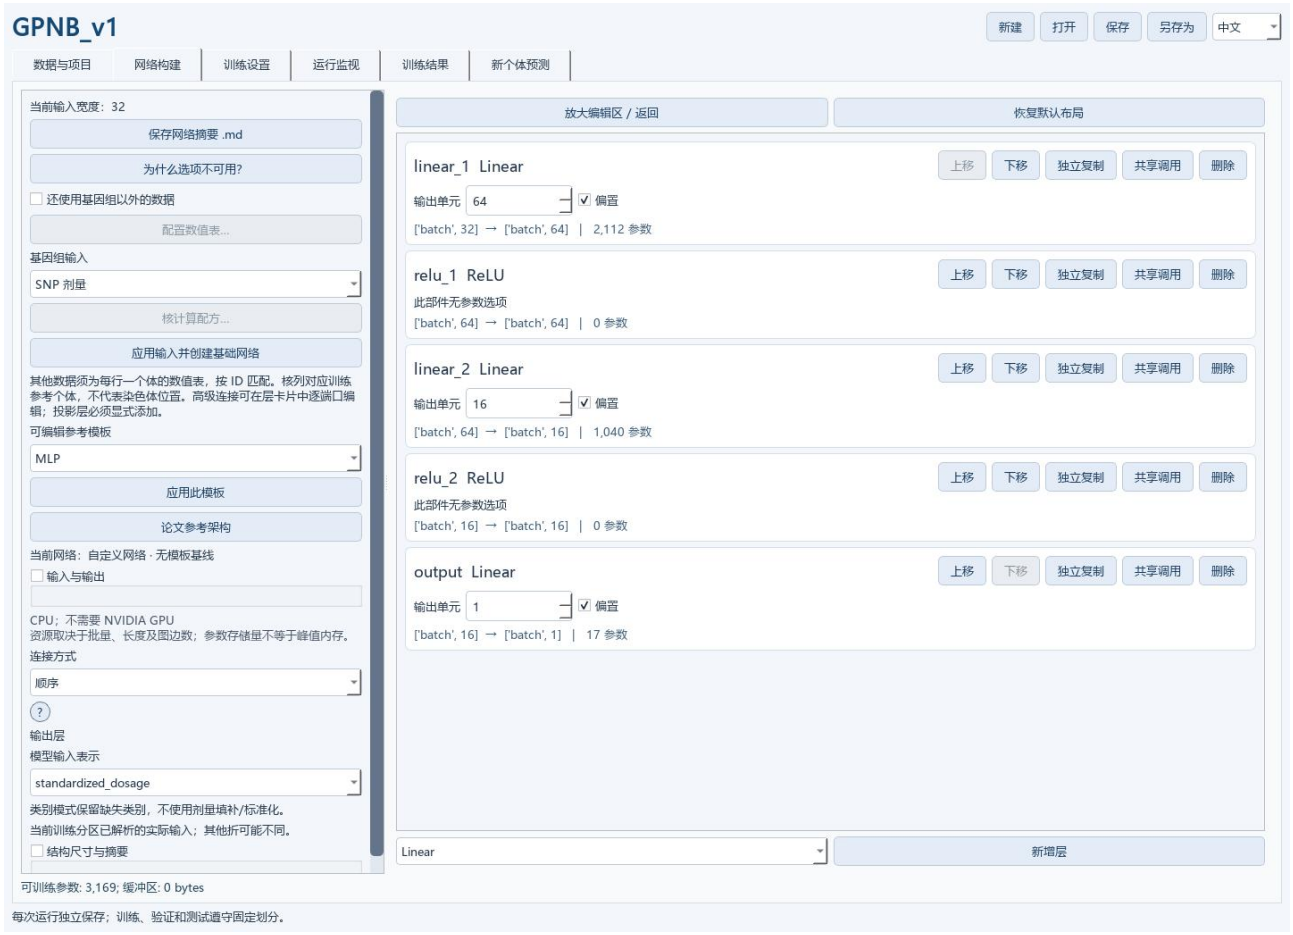

GPNB_v1
新建
打开
保存
另存为
中文
数据与项目
网络构建
训练设置
运行监视
训练结果
新个体预测
当前输入宽度：32
保存网络摘要 .md
为什么选项不可用?
还使用基因组以外的数据
配置数值表...
基因组输入
SNP 剂量
核计算配方...
应用输入并创建基础网络
其他数据须为每行一个体的数值表，按 ID 匹配。核列对应训练参考个体，不代表染色体位置。高级连接可在层卡片中逐端口编辑；投影层必须显式添加。
可编辑参考模板
MLP
应用此模板
论文参考架构
当前网络：自定义网络 · 无模板基线
输入与输出
CPU；不需要 NVIDIA GPU
资源取决于批量、长度及图边数；参数存储量不等于峰值内存。
连接方式
顺序
输出层
模型输入表示
standardized_dosage
类别模式保留缺失类别，不使用剂量填补/标准化。
当前训练分区已解析的实际输入；其他折可能不同。
结构尺寸与摘要
可训练参数: 3,169; 缓冲区: 0 bytes
放大编辑区 / 返回
恢复默认布局
linear_1 Linear
上移
下移
独立复制
共享调用
删除
输出单元 64
偏置
['batch', 32] → ['batch', 64] | 2,112 参数
relu_1 ReLU
此部件无参数选项
['batch', 64] → ['batch', 64] | 0 参数
linear_2 Linear
输出单元 16
['batch', 64] → ['batch', 16] | 1,040 参数
relu_2 ReLU
['batch', 16] → ['batch', 16] | 0 参数
output Linear
输出单元 1
['batch', 16] → ['batch', 1] | 17 参数
Linear
新增层
每次运行独立保存；训练、验证和测试遵守固定划分。

图 3 真实网络构建控件

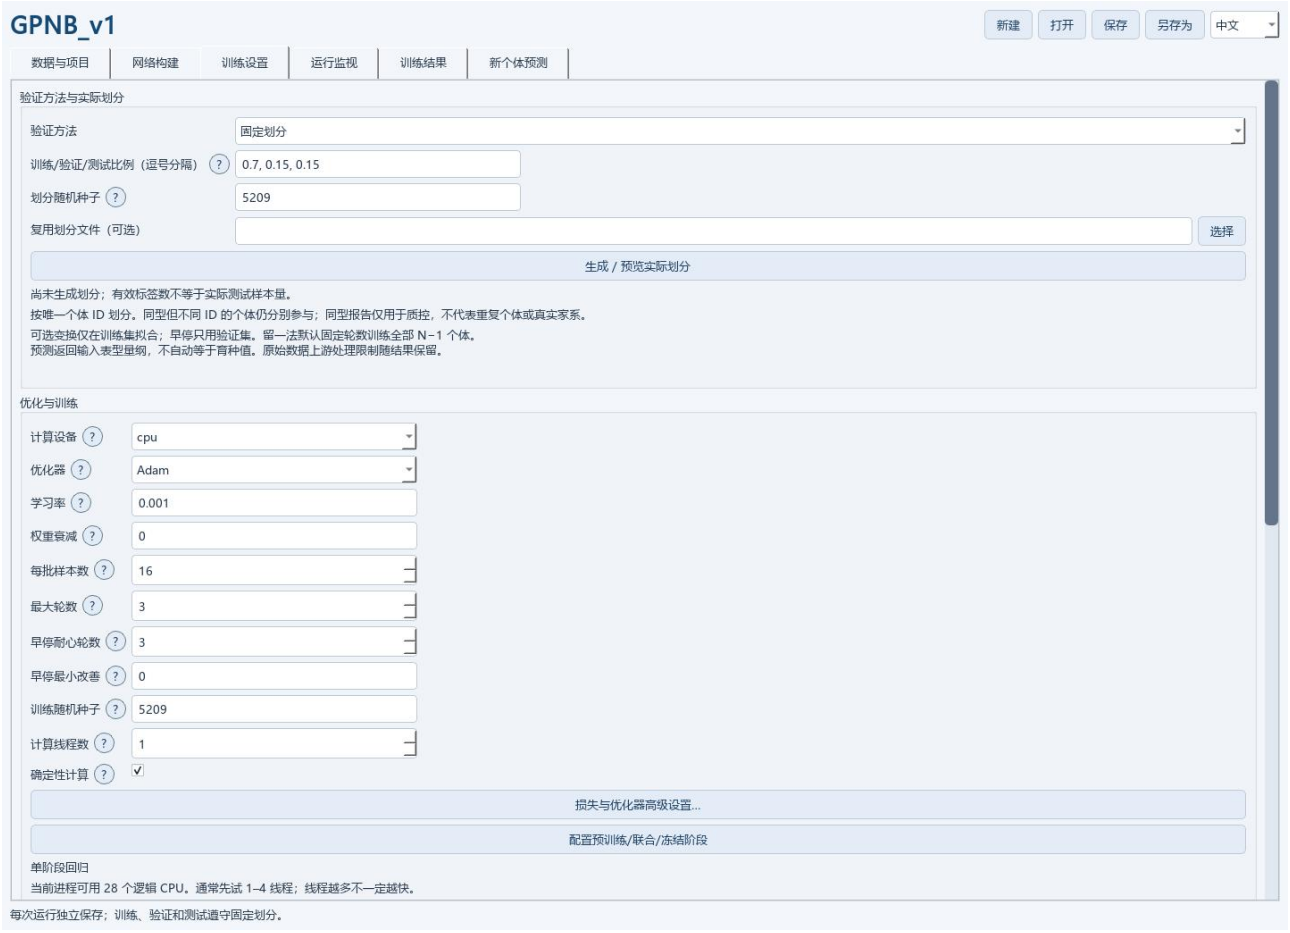


图 4 演示训练参数



图 5 运行前检查及训练就绪状态

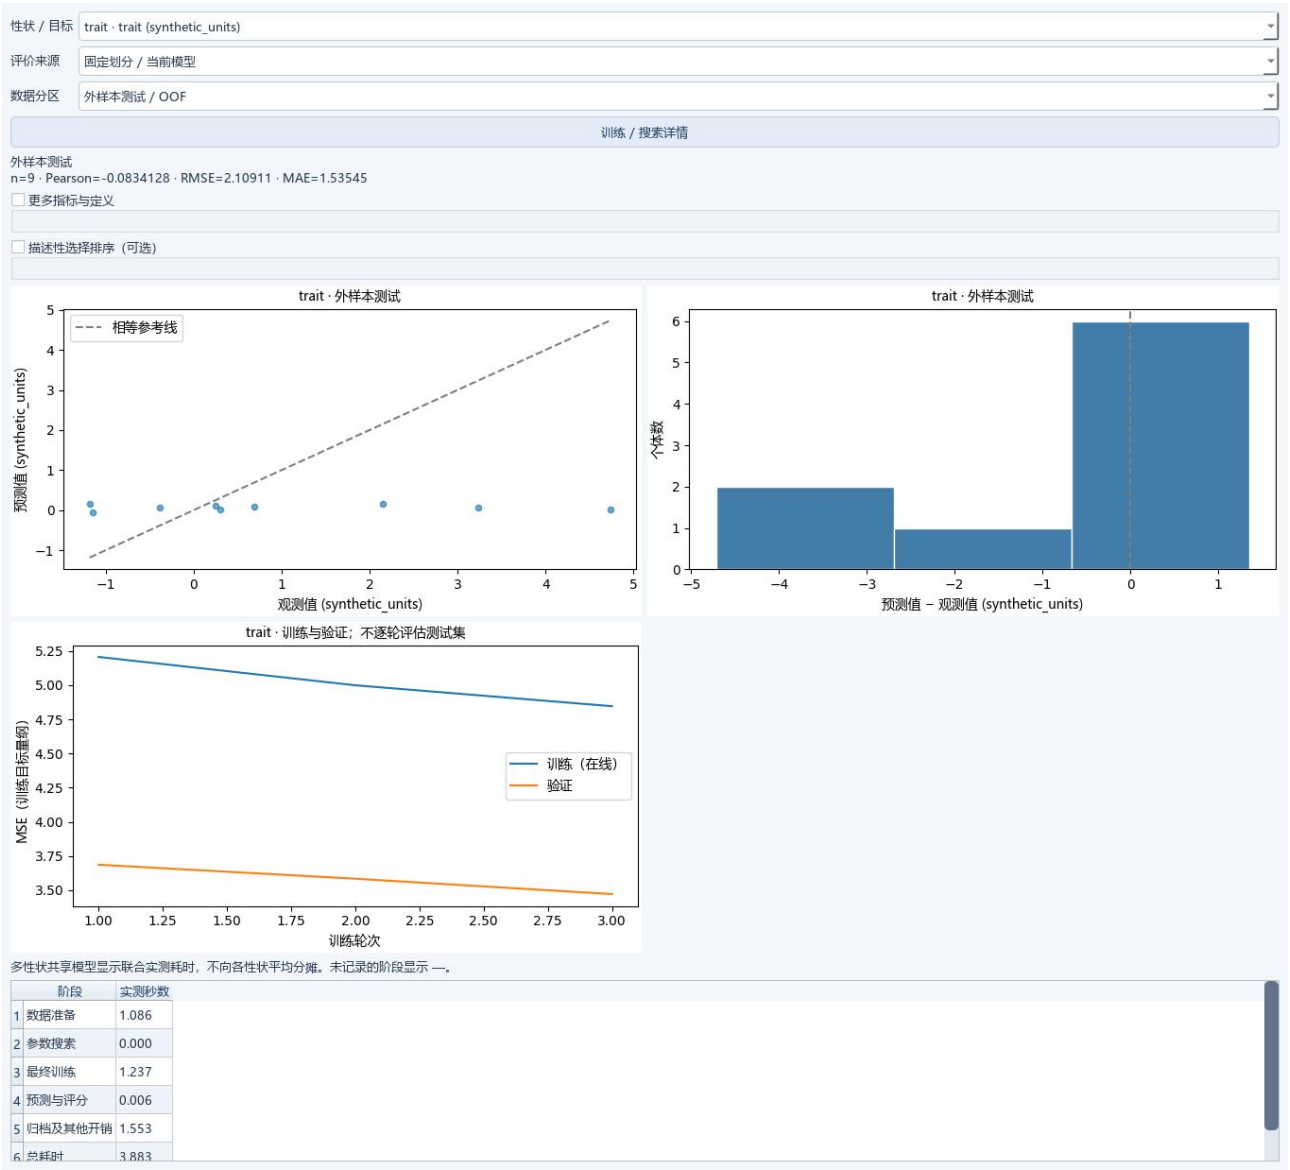


图 6 实际合成测试结果与学习曲线

3.2 预测新的合成个体

1. 打开“新个体预测”，用“选择…”选中“保存模型”生成的完整目录，再点击“加载并检查模型”。也可以选择已完成的实验目录；不要只选 `weights.pt`。

2. 用文件选择按钮选择 `examples/quickstart/query/genotypes.bed` 及配套 `.bim`、`.fam`，核对自动补全的配套路径。GUI 的预测与结果路径请使用选择器，不要手工输入相对路径，原因见路径限制。

3. 将“新队列名称”设为 `synthetic_query`。仅对此处独立模拟的示例，可选择“已独立核实均为新个体”，依据填写：`Independent synthetic cohort with disjoint QRY identifiers.` 真实材料没有独立身份依据时不能照抄这一声明。

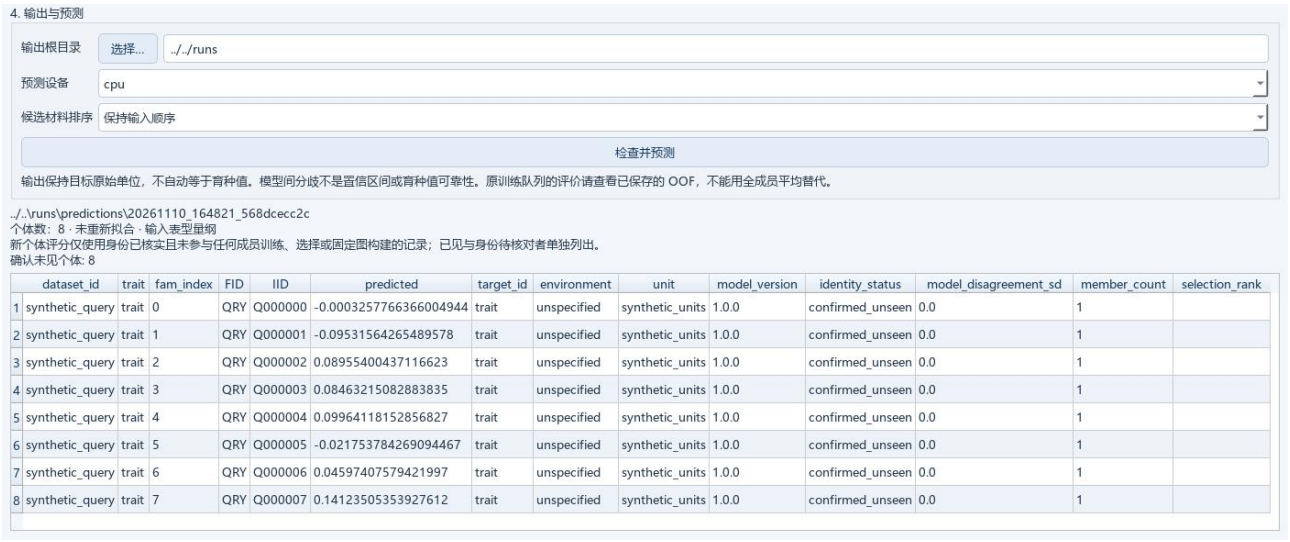
4. 暂不勾选“提供观测表型用于评分”，体验无标签预测。选择可写“输出根目录”、CPU，并保留输入顺序。

5. 点击“检查并预测”，应得到 8 个预测。目录位于 `runs/predictions/<时间戳>_<唯一后缀>`。`predictions.csv` 保存预测和个体信息，`report.json` 记录本次预测过程。未提供观测表型时，没有实测预测准确性。

6. 可另建一次输出，勾选“提供观测表型用于评分”，选择 `query/phenotype.csv`，设置逗号分隔、UTF-8、FID/IID 和性状 `trait`。这些观测只在预测结束后参与评分；带可选表型的 CLI 流程也已验证。



图 7 新个体预测控件



	dataset_id	trait	fam_index	FID	IID	predicted	target_id	environment	unit	model_version	identity_status	model_disagreement_sd	member_count	selection_rank
1	synthetic_query	trait	0	QRY	Q000000	-0.0003257766366004944	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	
2	synthetic_query	trait	1	QRY	Q000001	-0.09531564265489578	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	
3	synthetic_query	trait	2	QRY	Q000002	0.08955400437116623	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	
4	synthetic_query	trait	3	QRY	Q000003	0.08463215082883835	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	
5	synthetic_query	trait	4	QRY	Q000004	0.09964118152856827	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	
6	synthetic_query	trait	5	QRY	Q000005	-0.021753784269094467	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	
7	synthetic_query	trait	6	QRY	Q000006	0.04597407579421997	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	
8	synthetic_query	trait	7	QRY	Q000007	0.14123505353927612	trait	unspecified	synthetic_units	1.0.0	confirmed_unseen	0.0	1	

图 8 八个独立模拟个体的预测结果

若要尝试等价 CSV 输入，可打开 `examples/quickstart/project_matrix.json`。其中 `expected_dosage.csv` 与 BED 表达相同硬判定值，在 **0/1/2** 编码下明确将 `-1` 设为缺失标记。示例说明解释了它为何不使用 PLINK 来源清单。本次已验证两种输入解码后的数组完全相同。

4 准备数据并检查匹配

GPNB_v1 的界面支持 PLINK BED/BIM/FAM，以及明确指定编码方式的硬判定基因型文本矩阵。训练表型使用单独的 CSV、TSV 或空白分隔 TXT。Excel 工作簿、VCF、连续剂量矩阵，以及“位点为行、个体为列”的转置矩阵，均不能直接作为这里的输入；请先在其他工具中转换，并保留转换过程和等位基因编码说明。

本次随文档提供 examples/quickstart 合成示例；不包含真实研究数据或开发测试套件。下面的小表仅说明解析格式，不是模型评价基准。

4.1 填写数据与项目

进入**数据与项目**，填写**项目名称**、**数据集名称**和**运行输出目录**。数据集名称用于标记输出记录，不代表两个队列中的同名个体一定是同一个体。选择独立且空间充足的输出目录，再配置基因型和表型文件。

4.2 方式一 PLINK BED/BIM/FAM

选择 **PLINK BED/BIM/FAM**，填写同一次导出的 **BED**、**FAM** 和**位点信息 BIM**。

文件	格式与含义
`.bed`	SNP-major / variant-major 二进制 BED；文件头和字节数必须与 FAM/BIM 中的个体数、位点数一致。
`.bim`	六列，以空白分隔：染色体、位点 ID、遗传位置 cM、物理位置 bp、A1、A2。位点 ID 必须唯一；bp 为非负整数；A1、A2 不能相同。
`.fam`	六列，以空白分隔：FID、IID、父本、母本、性别、表型。FID/IID 组合必须唯一。实际训练目标来自单独选择的表型文件，不会自动使用 FAM 的表型列。

解码后的 0/1/2 表示 BIM 中 A1 的拷贝数。软件不推断倍性；FID 只是 ID 字段，不自动代表生物学家系。BED、BIM、FAM 应作为配套文件保留，不能单独调整 BIM 或 FAM 的行顺序。

4.3 方式二 数值矩阵

选择**数值矩阵 CSV / TXT**。每行一个个体，除 ID 列以外，每列一个具有唯一名称的位点：

CSV

```
FID,IID,rs1,rs2,rs3
F01,0001,0,1,NA
F01,0002,2,0,1
```

只有 IID 时可以使用：

CSV

```
IID,rs1,rs2,rs3
0001,0,1,NA
0002,2,0,1
```

逐项核对以下设置：

界面字段	初始设置与可选项
矩阵分隔符	初始为逗号 CSV；也支持制表符 Tab 和空白分隔 TXT。
文件字符编码	初始为 `utf-8`；也支持 `utf-8-sig`、`gb18030`。UTF-8 文件含 BOM 时选择 `utf-8-sig`。
基因型数值编码	初始为 `0 / 1 / 2`；也可选择 `-1 / 0 / 1`，软件通过加 1 转为内部 0/1/2。
ID 列（一个 IID 或 FID、IID；JSON）	初始为 `["FID", "IID"]`；单 ID 使用 `["IID"]`。列名不同时，按相同语义顺序填写实际列名。
缺失标记（JSON）	初始为 `["", "NA", "NaN"]`；按原始文本精确匹配，区分大小写。

界面字段	初始设置与可选项
等位基因依据	初始为**计数 BIM 中的 A1（需 BIM）**；也可选择**使用来源编码声明（不提供 BIM）**。

基因型必须是精确的编码文本。例如选择 0/1/2 编码后，`1` 有效，`1.0`、`0.7`、未声明的缺失标记或两侧带空格的数值会报错。连续剂量不会被四舍五入。选择 −1/0/1 编码时，`-1` 是有效基因型，不能同时作为缺失值。空白分隔 TXT 无法可靠表示空单元格，应从缺失标记中删除空字符串，改用例如 `["NA", "NaN"]`。

提供 BIM 时，矩阵的位点列名及顺序必须与该矩阵配套 BIM 完全一致，并确保数值计数 A1。不提供 BIM 时，必须填写有实际依据的**编码来源声明**，例如有记录的育种面板 / 供应商编码标识；预测时要求声明一致。此声明不能独立验证生物学等位基因方向，也不提供基因组位置信息。不能通过“不提供 BIM”来绕过已知的等位基因不一致。

可先点击**预览前 8 行**，检查分隔符、表头及编码。该预览范围有限，不能代替正式检查和完整导入。

4.4 表型文件与 ID

表型文件示例：

CSV

```
FID,IID,height,yield
F01,0001,12.4,3.8
F01,0002,NA,4.1
```

新项目的默认设置是逗号 CSV、`utf-8-sig`、**FID + IID**、ID 列 `["FID", "IID"]`，缺失标记 `["", "NA", "NaN"]`。表型的字符编码默认值与新数值矩阵不同。基因型仅有 IID 时，表型也必须选择 **IID** 匹配和 `["IID"]`；其他列名可以明确配置。

ID 始终按字符串匹配，不使用行号配对。`0001` 和 `1` 是不同 ID；ID 不能为空，也不能带前后空格。重复的表型 ID 键会被拒绝。只按 IID 匹配时，IID 必须在所有基因型行中唯一，即使原来的 FID/IID 组合并不重复。在 Excel 等软件中准备文件时，应将 ID 列保留为文本，避免丢失前导零。

点击**读取表型列名**，选择**目标性状**，并确认数值列确实是预测目标，而不是协变量。缺失表型不参与监督评价，不会被填补为真实观测。`Inf`、没有列入缺失标记的 `nan`，以及非数值性状内容属于无效值。新项目的主性状占位名称为 `trait`，需要替换为真实列名。

选择多个性状时，分别训练（每性状一个模型）创建独立任务；**联合训练（共享多输出网络）需要明确各目标的单位、权重等信息。点击应用所选性状与任务模式**后生效。选择列表中的 `n` 和 `NA` 是表型表内的有效值、缺失值计数；实际 ID 匹配和划分人数以检查结果、运行前预览为准。不同性状可有不同的可用个体。

4.5 训练前检查

点击**检查数据与匹配**，查看**检查摘要**、**个体匹配**、**性状统计**，必要时选择**仅未匹配与缺失**。

状态	含义
`matched_finite_label`	ID 匹配，所选性状有有限数值观测。
`matched_missing_label`	ID 匹配，但性状使用了已配置的缺失标记。
`matched_invalid_label`	ID 匹配，但所选性状无法解析为有限数值。

状态	含义
genotype_only	基因型个体没有匹配的表型 ID。
phenotype_only	表型 ID 没有匹配的基因型个体。

联合任务的可用个体由配置的多个目标共同判断；仅看主性状的显示不足以了解每个输出的缺失掩码。

界面上的这一步检查文件、ID 和表型，**不执行完整的基因型缺失扫描**；完整扫描发生在训练导入阶段。初步检查中的缺失基因型数量为空，表示“尚未扫描”，不是“没有缺失”。数值矩阵在读取个体时可能已经发现非法编码，但这也不等于完成了缺失率扫描。

界面最多显示 2,000 行。导出检查表

会将 `samples.csv`、`phenotype_only.csv`、`invalid_traits.csv`、`trait_statistics.csv`、`audit.json` 复制到新目录。**打开最近检查文件夹**可以查看完整检查目录，其中还包括位点记录和表型顺序记录。性状描述统计使用 ID 匹配后的有限观测，SD 的分母为 n−1；此处的 SD 不是交叉验证折间 SD。

高级：来源与重复样本检查可填写上游处理来源清单及基因型等价组。等价组不等于家系或群体；只有明确选择该划分策略时才约束分组。等价组 CSV 的表头为：

CSV

```
FID,IID,genotype_equivalence_group,group_size,basis
```

4.6 原始矩阵导出与训练预处理

导出原始 012 矩阵默认生成制表符分隔、以 `NA` 表示缺失的 `calls.txt`，以及 `matrix_config.json`、`encoding.json`、`report.json`；使用 BIM 编码时还有 `markers.bim`。前两列通常为 FID/IID；单 IID 来源只导出 IID，后续列为位点 ID。如果位点名与 ID 列名冲突，软件会使用替代 ID 列名并在配置中记录。此导出不填补、不筛选、不标准化基因型。

默认训练预处理则使用训练个体拟合的均值填补和基因型标准化；目标标准化初始关闭，MAF 和位点缺失率阈值初始未设置，训练集中全缺失的位点默认删除。每折独立拟合自己的处理状态，预测时复用保存状态，不在新队列上重新拟合。上游已执行的全队列处理，不能被后续的训练内处理消除。

独立的**配置并计算 GRM / 核矩阵…用于描述性矩阵导出；若要将核作为模型输入，应在网络构建**中选择训练内拟合的核配方。额外数值输入分支也需要明确按 ID 匹配的表格；新个体预测时，每个所需分支均应提供对应的新队列表格。

5 构建预测网络

配置好基因型和表型文件后，打开**网络构建**。新项目采用一个小型多层感知机：`Linear 64 → ReLU → Linear 16 → ReLU → Linear 1`。最后一个输出单元预测一个连续性状。这是一组起始设置，并不是针对您的群体和性状优化过的参数。

5.1 先选择输入，再编辑网络

在**基因组输入**中选择 **SNP 剂量**、**仅 GRM / 核特征**或 **SNP + GRM / 核特征**。使用核特征时，先打开**核计算配方…**。如果还需要协变量或其他组学特征，勾选**还使用基因组以外的数据**，再点击**配置数值表…**。附加表每行对应一个个体，特征列必须为数值，并通过 ID 匹配。

点击**应用输入并创建基础网络**，按已声明的输入生成网络。此操作会替换当前网络；如需保留原结构，请先另存项目。仅切换输入选项不会在后台悄悄重建网络。

核特征的列表示与训练参考个体的相似性，不是 SNP 位置。因此，仅核输入模式会限制需要原始位点的组件和模板。已有附加输入表时，软件也不会让单输入模板直接丢弃这些表。

5.2 用层卡片编辑网络

1. 在**可编辑参考模板**中选择模板并点击**应用此模板**，或保留初始 MLP。
2. 从上到下阅读层卡片，直接修改参数。对于 `Linear`，**输出单元**决定该层宽度，**偏置**决定是否使用截距项。
3. 在**新增层**旁选择组件。新增隐藏层会放在回归输出层之前；使用卡片按钮上移、下移、复制、共享调用或删除层。
4. **独立复制**生成独立参数；**共享调用**复用另一个层的参数与保存状态。修改拥有参数的层时，对应共享调用的参数设置也会同步。
5. 展开**结构尺寸与摘要**查看推导的输入/输出尺寸和参数存储量。点击**保存网络摘要 .md** 保存可阅读的结构说明。

输入特征数来自实际数据；训练内位点筛选之后，保留特征数可能改变。界面不提供随意填写一个假设特征数的操作。数据尺寸尚未确定时，部分形状会显示未解析。**放大编辑区 / 返回**可以扩大卡片区域，**恢复默认布局**用于恢复布局。当前界面使用层卡片和尺寸摘要，不提供交互式网络结构图视图。

组件下拉框会根据当前输入类型和插入位置筛选。找不到某个组件时，点击为什么选项不可用？查看原因。组件可能需要不同的数据布局或明确的图配置，并不表示软件没有实现它。

5.3 顺序网络与分支网络

连接方式 → 顺序表示层按顺序串联。选择**分支**后，每张层卡片显示输入端口，**输出层**指定最终预测出口。残差连接、多输入表、掩码、共享调用、查询与上下文分开的注意力，均需要显式分支连接。多输入端口组件会自动要求分支模式。

软件会检查连接和尺寸。例如，`Add` 的输入必须兼容，循环层需要序列输入而不是平面位点向量。软件不会自动插入投影层；请明确增加所需的 `Linear`、布局转换、池化或展平组件。只有现有连接已经构成一条简单链时，才能从分支模式返回顺序模式，不会自动丢弃分支。

单性状任务应保留一个输出单元的线性回归头；多目标任务的输出宽度必须等于目标数。当前模型合同也允许在线性输出之后显式添加一个 `Dropout`，预测时该 Dropout 会关闭。回归输出后不能随意接任意激活函数。

5.4 模板与组件范围

当前注册了 **89 个组件**，完整参数见组件参考。范围包括全连接层、激活、归一化、卷积、池化、循环网络、分词、注意力、图运算、输入融合和重建。组件是单个构件，模板则是已经连接好的起始网络。

网络构建器提供以下 **30 个通用模板**，是否出现在当前菜单中取决于已声明的输入。

用途	模板名称	需要检查的内容
全连接与残差回归	MLP、Residual、GatedAdd、GatedMLP、DenseMoE	层宽、正则化及分支连接
沿位点顺序卷积	CNN、Local、SE、TCN	保留位点数、卷积核、池化及内存
循环处理	RNN、LSTM、GRU	序列布局及读出方式；通用模板会先池化位点位置再进入循环层
分词与注意力	Tokens、SelfAttention、Transformer、CrossAttention、Mixer、AttentionPool	token 数、嵌入宽度、掩码及注意力内存限制
基因型类别	Categorical	使用显式基因型/缺失类别，不走连续剂量填补和缩放
位点图	GCN、GraphSAGE、GIN、GAT	应用模板前先配置位点图
多输入与参考特征	MultiInput、ReferenceGraph、KernelMLP、SNP+Kernel、FeatureAffine	明确所需的数值表、核模式或个体参考协议
网格与辅助重建	GridCNN、Autoencoder	网格是用户安排的布局；Autoencoder 增加重建头及显式训练阶段

卷积窗口、位点分块、token 位置和通用网格按保留位点/文件顺序工作，不会自动识别染色体、物理距离、LD 区块或生物学图像。位点图和个体参考图是两类不同输入，分别通过**导入位点图 / 查看映射**和**个体参考图协议**配置。固定队列的个体参考协议不能用于任意未知新个体；需要预测新个体时，应选择符合该用途的归纳式训练参考协议。

5.5 明确选择论文架构与参数

点击**论文参考架构**查看八个可用适配：**DeepGS、DeepGP、DLGWAS、deepGBLUP、WheatGP、Cropformer、DNNGP、GPformer**。应用前阅读结构、输入要求和参数预览。

对话框提供**应用文献已核实设置**和**仅应用结构，保留训练设置**两种模式。点击**应用以上预览**执行显示的修改；尚未发生后续项目编辑时，**撤销本次应用**可恢复之前配置，避免撤销误删后续修改。如果当前存在分阶段设置，需要明确选择是否移除。项目的预处理、划分和搜索设置会保留；已有学习率调度也可能继续保留，除非预览明确修改了它。

预设	实际应用的训练字段
DeepGS	SGD；学习率 0.01；momentum 0.5；权重衰减 0.00001；batch 30；最大 6000 轮；训练种子 0；MSE
DeepGP	仅 MSE
DLGWAS	Adam；学习率 0.001；batch 250；最大 1000 轮；MSE
deepGBLUP	不额外应用训练标量设置
WheatGP	Adam；学习率 0.005；权重衰减 0.0001；batch 64；最大 300 轮；MSE；梯度范数上限 1；StepLR 每 90 轮乘 0.1
Cropformer	Adam；学习率 0.001；权重衰减 0；batch 32；最大 100 轮；MSE

预设	实际应用的训练字段
DNNGP	不额外应用训练标量设置；不会自动执行 PCA 或多组学拼接
GPformer	Adam；学习率 0.0001；权重衰减 0.00001；batch 32；focal MAE；$\beta = 0.5$，$\gamma = 1$

这些选项是可编辑的原生 PyTorch 适配。DNNGP 和 GPformer 属于基于论文的结构映射，deepGBLUP 选项实现神经子图，不包括完整 GBLUP 方差估计/联合优化；Cropformer 保留映射代码的单 token 注意力语义。GPformer 不含 GWAS 引导的 KGM 分支。

6 选择评估协议

打开**训练设置 → 验证方法与实际划分**。先决定哪些个体需要留出，再比较模型设置。当前默认按唯一的个体 ID 划分。不同 ID 即使基因型完全相同，也仍被视为不同个体；基因型模式质控不会据此推断重复身份或系谱。普通随机个体划分不能直接证明对新家系、新群体、新世代或新环境的预测能力。

验证方法	当前行为	需要核对的设置
固定划分	一次训练/验证/测试划分，默认比例为 0.70/0.15/0.15	比例、划分种子、可选的已有划分文件
五折交叉验证	五个外层测试折；每个外层训练集再留出内部验证子集	外层/内层划分种子；外层训练集内验证比例，默认 0.20
十折交叉验证	十个外层测试折，每折有自己的内部验证子集	与五折相同
留一个体	每折留一个个体，默认在其余所有有效个体上固定轮数训练	留一训练协议、实际划分预览、实际模型数确认

例如，五折 CV 的内层验证比例为 0.20 时，每折大约用总有效个体的 64% 训练、16% 选择检查点、20% 作外层测试。十折对应约 72%/18%/10%。这些比例用于理解流程，实际整数人数以生成的计划为准。

点击**生成 / 预览实际划分**，检查各部分人数及每个性状的缺失表型影响。有有效表型的个体数并不自动等于外层测试数。留一法需要先确认显示的外层拟合次数，才能进行运行前检查和训练。界面还保留明确使用内部留出集的留一训练协议，供已有工作流使用；该协议实际训练人数少于 N−1，并采用验证早停，与默认的全 N−1 固定轮数协议不同。

固定划分可以使用**复用划分文件（可选）**；交叉验证可以使用**复用 cv_plan.json**。复用保留计划声明的成员关系；修改数据或科学设置可能使计划失效。比较不同模型时，应保持相同有效群体和划分计划。若要更换种子重复评估，需要分别保存配置并运行；选择五折并不自动执行三次重复或 15 折。

7 设置训练参数

以下是**新建项目默认值**。打开已保存项目或应用论文预设后，当前值可能不同。训练种子与划分种子是两个独立设置。

界面字段	默认值	含义与可选范围
计算设备	cpu	`cpu` 或 `cuda`。CUDA 需要已安装且可用的 NVIDIA 环境；不可用时不会静默改用 CPU。
优化器	Adam	Adam 或 SGD。
学习率	0.001	正数更新步长，应通过内部验证比较候选值。
权重衰减	0	非负优化器权重衰减，不自动等价于论文的逐层正则化。
每批样本数	64	每次更新的个体数，至少为 1；减小它可以降低部分内存开销。
最大轮数	100	普通训练的上限，早停可能提前结束。
早停耐心轮数	20	验证损失连续未达到所需改善的轮数。
早停最小改善	0	重置耐心计数所需的非负改善阈值。
训练随机种子	5209	控制模型/训练随机性，整数范围 0–4294967295。
计算线程数	2	正整数；界面上限依据当前进程可用 CPU 亲和性确定。
确定性计算	开启	请求支持的确定性运算，不等于保证不同硬件、依赖版本或模型实现结果相同。
高级设置中的损失函数	mse	`mse`、`mae` 或 `focal_mae`。
划分随机种子	5209	用于固定划分；CV 使用单独的外层/内层种子，初始也为 5209。

采用验证选择时，软件恢复**实际记录中验证目标最小的权重**。`min_delta` 只控制耐心计数，不决定是否保留一个更小的真实验证最小值。固定轮数训练没有验证早停，保留最后一轮。外层测试结果不用于选择检查点。

7.1 损失与优化器高级设置

点击损失与优化器高级设置…查看下列选项。

选项	未配置时的默认状态	含义
损失函数	mse	MSE 使用平方误差；MAE 使用绝对误差。
SGD momentum	0	用于 SGD，接受 0–1。
Focal β / Focal γ	0.5 / 1	focal MAE = `tanh(β × 绝对误差)^γ × 绝对误差`；β > 0，γ 为 1–100。
学习率调度	None	可显式启用 ExponentialLR 或 StepLR。
每次衰减乘数	对话框初始显示 0.95	仅启用调度时生效，范围为大于 0 且不大于 1；这是可编辑示例，不是通用论文参数。
衰减间隔（轮）	对话框初始显示 90	仅 StepLR 使用，必须为正整数。
梯度范数上限	空白/关闭	输入正数启用梯度裁剪。

调度器在每轮训练后更新。损失使用当前训练目标尺度：如果启用了目标标准化，训练损失也处于该标准化尺度。预测值及回归误差指标会转换回输入表型的尺度。Pearson 相关与 RMSE 衡量不同方面，均不会自动变成育种值准确性估计。

8 配置训练内预处理

新项目默认启用**训练内预处理**。填补、中心和尺度等统计量从对应训练分区估计，再用于验证、外层测试和新个体。每个 CV 折独立拟合预处理；内部搜索划分及最终全数据重拟合也遵守各自训练边界。

字段	新项目默认值	可选项与含义
缺失基因型处理	mean	`mean`、`none`、`mode`、`median`、`knn`。均值/中位数可产生小数剂量，众数并列时选较小编码。
训练内全缺失位点	drop	`drop`、`error`、`zero_with_warning`；mode/median 无法从全缺失训练位点估计填充值。
标准化基因型	开启	使用训练填补后的中心和尺度，常量特征用尺度 1。
标准化目标	关闭	开启后使用训练均值和总体标准差，输出预测时逆变换。
训练集最低 MAF	空白/不筛选	可填 0–0.5。
训练集最高位点缺失率	空白/不筛选	可填 0–1。

关闭预处理会把填补设为 `none`，关闭基因型与目标标准化，并清除位点筛选条件。格式转换和 ID 对齐仍执行。连续剂量存在缺失时会阻止计算；类别输入仍保留显式缺失类别。附加数值表继续按自己的预处理配置执行。重新启用开关时，不会悄悄恢复之前隐藏的全部变换，请重新检查可见字段。

选择 KNN 后打开**训练参考 KNN 参数…**。默认 5 个邻居、至少 1 个共同观测位点、等权、连续均值输出，也可选择反距离权重或硬判定投票。默认参考人数上限 20,000，参考存储上限 268,435,456 字节，工作存储上限 67,108,864 字节。只使用冻结的训练参考；查询个体不会互相成为参考。没有合适邻居时使用随模型保存的逐位点后备规则。即使机器还有可用内存，大样本任务也可能触及这些显式上限。

9 搜索少量超参数组合

勾选**启用参数搜索**，点击**配置随机 / 网格搜索**。选择参数，输入以逗号分隔的明确候选值，再点击**保存设置**。例如学习率 `0.0001, 0.001, 0.01` 与 batch `16, 32` 共形成六个组合。

搜索设置	初始值	行为
方法	random	不放回抽取组合；`grid` 遍历全部组合。
候选数上限	6	范围 1–1000；网格搜索必须能覆盖全部组合。
抽样 / 内部划分种子	5209	控制候选抽样，以及需要额外建立的内部留出集。
内部验证比例	0.20	范围 0.01–0.49；只在需要建立新内部留出集时使用，例如全训练留一法；已有验证成员关系会保留。

搜索设置	初始值	行为
初始候选字段	学习率与 batch	学习率 0.0001/0.001/0.01；batch 16/32。

可搜索的训练字段为优化器、学习率、权重衰减、batch、epochs、patience、min delta 和 momentum；也可以选择现有层的已注册参数。每个参数可列出 1–100 个不重复候选值，每次搜索包含 1–12 个参数字段，组合空间上限为 1,000,000。搜索不会自动改变预处理、数据划分或未列出的任意训练字段，目前要求单阶段训练。

候选按**已选择的验证损失**（`mse`、`mae` 或 `focal_mae`）排名，尺度与训练拟合的目标尺度一致，不按外层测试 Pearson 选模型。有验证分区时使用该分区；默认留一法中，搜索先从 N−1 个外层训练个体建立内部划分，再把选中候选按内部选出的轮数在全部 N−1 个体上重训。被留出的个体始终不参与选择。

每个外层折最多需要“候选数上限 + 1 次正式训练”，分别训练多个性状时还要乘以性状任务数。无效候选会记录并可跳过；所有候选均失败则搜索失败。通过 `search/trials.json`、各候选记录、选中项目及摘要文件核对实际设置与失败原因。界面的预检数量和工作单元进度不是预计完成时间。

10 检查、启动与监控训练

1. 保存项目，核对实际划分；如使用留一法，确认实际模型数。
2. 点击**运行前检查**。检查使用实际输入数据、训练内预处理、计划的各折和相关搜索候选，验证尺寸并在所选设备上进行有界的前向/反向数值探测。探测权重不会交给正式训练。
3. 查看检查清单和报告。修改配置、输入内容、代码、依赖或分配上限，可能使已有检查失效。部分候选失败时，仍可保留有效候选继续搜索。
4. 检查通过后点击**开始训练**。GUI 通过工作进程运行任务，同一时间只运行一个任务。
5. 在**运行监视**中查看当前性状/折/候选、轮次、最佳验证轮次、学习曲线、进程耗时和内存。**训练指南？**根据训练/验证历史解释常见曲线形态，不修改参数，也不读取外层测试指标。

检查通过表示有界探测通过，并不保证完整大规模训练一定不超内存。参数和缓冲区存储量不等于总内存：激活、梯度、优化器状态、注意力分数、参考图和 batch 也会占用内存。默认模型分配上限为参数加已注册缓冲区共 256 MiB，部分组件还有元素数量上限。检查失败时，先定位报告中的层，再调整相关层宽、token 数、batch 或图复杂度。

普通 BatchNorm 在最后一个训练 batch 对每通道只剩一个有效观测时可能失败，可检查 batch 设置或归一化方式。包含 AdaptiveMaxPool1d 的 CUDA 模型通常会自动关闭严格确定性；显式要求它不支持的严格 CUDA 反向传播会报错，应核对结果中保存的实际生效设置。

监视界面显示进程 RSS 及 PyTorch CUDA 已分配/保留内存，不是整机内存或全部 GPU 使用量。归档 RSS 峰值按 0.1 秒间隔采样，可能错过短暂峰值；CUDA 峰值仅覆盖 PyTorch 分配器，不含驱动及其他进程。总体进度按计划工作单元计数，不表示耗时百分比。

点击**取消当前任务**会在安全计算边界请求停止；10 秒内仍未退出时，GUI 可以强制结束工作进程。中断输出保留未完成/失败状态，不能作为成功模型。取消不等于支持任意检查点续训。继续工作时保留已有结果并建立新任务；分别训练的性状批任务可通过自己的重试流程，在输入、代码、环境均未改变时复用已核验完成的子任务。

11 分别训练多个性状，或联合输出

请按生物学问题选择任务。多个独立单性状模型，与一个共享多输出模型，在模型结构和损失含义上不同。

分别训练。 在数据界面勾选多个表型列，选择**分别训练（每性状一个模型）**，再点击**应用所选性状与任务模式**。每个性状保存独立模型与结果目录。共享 ID 计划投影到各性状的有效标签，因此缺失表型可能导致实际人数不同，而不是为每个性状悄悄重新随机划分。子任务按顺序执行；一个性状失败会单独报告，不会自动抹去已成功任务。分别训练要求单输出网络，不能同时启用联合目标头；应用此模式时，界面会清除单性状复用划分文件设置，因为批任务使用自己的共享计划。

联合输出。 在**网络构建 → 输入与输出**中打开**单目标 / 多性状 / 多环境输出**。选择**新个体、固定已知环境**协议，添加 2–64 个目标，填写每个目标的 ID、表型列、性状、环境、单位、校正说明和正权重，再点击**应用目标头**。线性输出宽度会变成目标数，第一个目标列同时作为主要显示性状。

表型采用宽表：一行一个个体，每个性状/环境观测占一列。同一个体的所有目标一起划入同一分区。缺失观测会从损失中屏蔽，但每个目标仍必须有训练观测；存在验证分区时，每个目标也必须有验证观测。每个目标的均值/尺度只用已观测训练标签估计。损失按声明的权重组合各目标损失，因此需要认真确定单位、标准化和权重。

目标 ID 和表型列必须唯一，每个性状/环境组合只能对应一个头。目标列不能同时成为预测输入特征。辅助表型仅作为训练标签，不是预测新个体时必须输入的表型。当前协议支持已声明环境下的新个体，不支持未声明新环境的外推。联合目标目前不能与分阶段/重建目标组合；目标矩阵上限为 2000 万个单元。

12 可选的分阶段训练

只有模型结构和研究问题需要时，才打开**配置预训练/联合/冻结阶段**。每个阶段声明模式、轮数、回归/重建权重及冻结的层 ID。最多支持八个阶段，各阶段轮数会替代全局最大轮数。

阶段模式	权重要求	用途
pretrain	回归为 0，重建 > 0	训练已声明的重建目标。
joint	两个权重均 > 0	同时训练回归和重建。
regression	回归 > 0，重建为 0	训练表型回归。

重建阶段必须有明确的重建头，最后一个阶段必须包含回归目标。通用 Autoencoder 模板创建“重建预训练 → 回归”两阶段，每阶段初始轮数都等于当时的全局轮数；回归阶段冻结模板记录的编码器层。因此，应用模板后要检查阶段表，不能以为全局轮数只计算一次。

每阶段重新初始化优化器、学习率调度和早停状态。有验证集时恢复各阶段自己的最佳权重；固定轮数时保留最后权重。冻结同时作用于参数和运行统计，并遵循实际共享模块关系。重建损失只使用已观测基因型，不把填补值当成已知观测。外层测试数据不参与任何训练目标。当前分阶段工作流不能同时启用超参数搜索，也不能与联合多目标输出组合。

13 为新个体训练最终模型

完成所选流程的评估后，在**训练结果**页点击**按当前项目训练全数据最终模型**。该操作使用**当前项目配置**，不会自动挑选测试相关最高的一折。

最终模型操作先建立新的内部训练/验证选择划分，不设置外层测试。默认内部验证比例为 0.20；启用搜索时使用搜索配置中的比例。内部选择参数与轮数后，模型重新初始化，在全部有有效标签的个体上按选定轮数训练。预处理、参考/核状态也会在全部这些训练数据上重新拟合。分阶段模型使用各阶段内部选出的轮数。

输出分开保存内部选择和最终 `model`，并记录来源。它**不会产生新的独立测试准确性**。此前 CV 分数描述的是被评估的训练流程，不能改名成为对最终模型新测得的独立分数。导出完成的最终模型包用于新个体预测，同时保留评估结果和选择记录作为支撑材料。

14 查看、导出和解释结果

进入**训练结果**。加载已有结果时，点击**打开其他结果…**，选择已完成结果目录，再点击**加载结果**。请通过目录选择器取得绝对路径，不要在模型 / 结果目录字段中手动输入相对路径。页面依次显示 **1. 数据概览**、**2. 实际模型与设置**、**3. 预测结果**、**4. 保存与应用**。未完成归档或已被修改而无法通过校验的文件，不能作为完整结果使用。

14.1 先确认评价范围

解释数值或导出报告前，先选择**性状 / 目标**、**评价来源**和**数据分区**。

选择	含义
合并 OOF（每个体一次外测），配合**外样本测试 / OOF**	汇总已保存的外层测试预测；在这次 CV 中，每个合格个体对每个目标贡献一次外测预测。
折 N	查看该折的实际模型、参数及所选分区。各折可能选择了不同参数。
验证（参与选择）	验证集参与模型或轮次选择，其指标不是独立的最终测试指标。
训练拟合（非外样本）	对训练观测的拟合效果。CV 中需要选择单折，不合并个体在多个训练折中的重复出现。
最终模型 / 内部选择（无独立测试）	最终重拟合没有产生新的独立测试成绩，应参考原评价实验。

页面显示观测—预测图、逐个体误差分布、已记录的学习曲线，以及适用的逐折 Pearson 图。**训练 / 搜索详情**可查看拟合和搜索记录。未记录耗时显示为不可用；共享多目标模型的联合耗时不会被虚构地平均分摊到各性状。

Pearson r 衡量线性相关性，没有单位。RMSE、MAE 衡量预测误差，单位与输入表型相同；RMSE 为 `sqrt(mean((预测 - 观测)^2))`。**更多指标与定义**还包括 Spearman、R^2、Bias、校准和相对训练均值基线改善。R^2 可以为负，不等于 Pearson r 的平方。Bias 为 mean(预测−观测)，正值表示整体高估。校准拟合“观测 = a + b × 预测”，仅用于诊断，不自动修正预测值。

以下三种统计量应分别报告：

1. **合并 OOF Pearson**：将外层测试观测和预测拼接后计算一次相关系数。
2. **逐折 Pearson 均值 ± SD**：有效折相关系数的等权均值及样本标准差，`ddof=1`。不可计算的相关系数被排除，而非替换为 0，应同时保留有效折数 / 总折数。各折共享训练观测，因此该 SD 是描述性折间波动，不是置信区间。留一个体、留一基因型等价组采用合并 OOF 报告，不使用普通逐折 Pearson 汇总。

3. **新个体预测的模型间分歧 SD**：同一个体在所有加载成员之间的预测总体标准差，`ddof=0`，单位与目标相同。它既不是前两种汇总，也不是置信区间或育种值可靠性。

观测恒定、预测恒定或观测数不足 2 时，Pearson 不可计算。应保留原因，而不是填 0。论文中跨多个数据集、种子或重复运行的“均值 ± SD”需要另行定义汇总范围；界面不会自动把独立运行合并为重复交叉验证分析。

如果启用了 GPNB 的目标标准化，输出会按保存的状态反变换回输入训练表型的尺度。软件不会推断或自动撤销外部进行的对数转换、校正或单位变换。例如输入是 log(产量)，返回的尺度仍为输入的 log(产量)。单位标签是元数据，不会触发单位换算。表型预测值不自动等同于估计育种值。

14.2 选择保存内容

在 **4. 保存与应用**中设置**保存位置**及可选的**保存名称**。每次操作都会创建带唯一后缀的新目录。

按钮	保存内容与用途
导出结果	包含指标、逐样本记录、图、实际设置和耗时的结果报告。**结果导出范围**默认**全部性状**；选择**当前性状**可限制到当前目标，并保留所选分区和折。
保存模型	冻结预测模型包，含全部声明成员、张量权重、网络结构、已拟合预处理和必要参考状态，用于新个体预测。
导出完整实验	带保存源码、依赖记录和 `reproduce.py` 的实验副本。**完整实验附带输入数据**初始不勾选；需要在新位置完整重训时，再勾选带入输入数据。

导出结果

按钮实际位于保存区域，作用于上方的结果视图。普通报告包括 `report.html`、顶层 `metrics.csv` 及 `target_001`、`target_002` 等目标目录。各目标目录包含 `predictions.csv`、`summary.json`、`timing.csv`、适用的 `fold_metrics.csv` 和图片。默认同时导出 PNG、SVG、PDF；PNG 为 **150 dpi**。投稿时可使用矢量 SVG/PDF，或另行明确指定出版图片规格；该按钮不会自动生成 600 dpi 位图。应完整保留报告目录，以便离线 HTML 正确读取图片和 CSV。

对于 CV，`fold_metrics.csv` 始终记录全部折的外层测试指标，即使当前报告显示某一折或训练 / 验证分区；其中 `partition=test` 明确标记了这一范围。逐折指标不是学习曲线的逐轮数值。

模型包不依赖原始训练输入文件，也不复制训练表型值和完整原始基因型文件，但仍含个体身份信息；KNN 填补、核模型和个体图模型还可能包含预测所需的参考基因型，因此不是匿名档案。模型包需要兼容的 GPNB/PyTorch 环境，不是独立可执行程序。必须完整保留 `complete.json`、`model_package.json` 和所有成员目录。

完整实验可在兼容 Python 环境中使用 `reproduce.py verify`、`predict`，以及在包含训练数据时使用 `train`。它不内置 Python/PyTorch；重训会核对保存的 Python / 数值库版本及原设备，不承诺跨硬件逐位一致。历史归档若没有保存源码快照，不能用当前安装的源码冒充当时源码。请完整保留原归档。

按当前项目训练全数据最终模型是独立操作：根据当前项目进行内部选择，再对合格训练个体重拟合，不是直接挑选外层测试成绩最高的一折。**更多：比较交叉验证结果 → 比较相同划分的结果**用于兼容的已完成 CV 结果，不能将不同划分当作配对结果比较。

14.3 CSV 字段参考

CSV 使用 UTF-8。用电子表格软件打开时，将 FID/IID 按文本导入，保留前导零。`fam_index`、`training_bim_index`、`new_bim_index` 等行索引从 0 开始；CV 的原始折号从 1 开始。固定划分训练记录使用 `fold=0`。

训练结果 `predictions.csv`：

CSV

```
dataset_id,trait,fold,seed,model_sha256,partition,fam_index,FID,IID,observed,predicted
```

联合多目标训练追加 `target_id,environment,unit`。CV 根目录的 `predictions.csv` 只有 OOF 测试行；各折目录保留各自训练、验证、测试记录。多目标的缺失观测可以为空，但预测值仍保留。

结果报告 `metrics.csv`：

CSV

```
target_id,trait,unit,n,pearson,pearson_reason,rmse,mae,mse,spearman,spearman_reason,r2,r2_reason,bias,calibration_intercept,calibration_slope,calibration_reason,baseline_mse,baseline_improvement
```

`n` 是当前视图中参与计算的有限观测 / 预测对数。不可计算指标保留为空，在适用字段中记录原因。

结果报告 `fold_metrics.csv`：

CSV

```
partition,fold,n,pearson,pearson_reason,rmse,mae
```

新个体预测 `predictions.csv`：

CSV

```
dataset_id,trait,fam_index,FID,IID,predicted,target_id,environment,unit,model_version,identity_status,model_disagreement_sd,member_count,selection_rank
```

启用表型评分时追加 `observed,prediction_minus_observed,phenotype_match`。保持输入顺序时 `selection_rank` 为空；选择排序后，它是各目标内部从 1 开始的名次，并列保持输入顺序。CSV 中记录模型版本，`report.json` 保存各成员版本及模型 / 权重 / 预处理哈希。

新个体预测 `marker_alignment.csv`：

CSV

```
training_bim_index,new_bim_index,marker_id,retained
```

该文件描述第一个成员；集成预测还输出 `marker_alignment_member_N.csv`。`retained` 表示该成员训练时保留的位点。

新个体预测 `samples.csv`：

CSV

```
fam_index,FID,IID,missing_genotypes
```

预测目录还包含记录身份、评分、输入及成员来源的 `report.json`，以及 `environment.json`、`prediction_values.npy`、`model_disagreement.npy` 和完成校验清单。分析时请复制 CSV，不要原地修改已封存归档中的文件。

15 预测新个体

1. 打开**新个体预测**，使用**模型包或已完成结果目录**旁的**选择…按钮取得目录绝对路径，再点击加载并检查模型**，不要手动输入相对模型目录；也可从已加载结果点击**使用此模型预测 →**。加载后，界面显示目标、基因型要求及所需额外数值输入表。
2. 填写**新个体 BED**、**配套 BIM**、**配套 FAM**，或配置**数值矩阵（CSV/TSV/TXT）**。每个额外输入分支都需要对应的新队列表格，软件不会自动复用训练协变量文件。

3. 填写**新队列名称**，初始为 new_cohort，并选择正确的**个体身份来源**；仅更改队列名称不能建立个体身份关系。

4. 如需评价，勾选**提供观测表型用于评分**并选择新的表型文件。加载模型后会建议原有列名约定，但不会复用训练表型值。多目标评分沿用原目标列名。

5. 设置**输出根目录**、**预测设备**（初始为 cpu）和**候选材料排序**。默认**保持输入顺序**。点击**检查并预测**。

新数据必须包含训练原始位点中的全部位点，包括后来被该成员过滤掉的位点。新队列的位点顺序可以与训练顺序不同：软件按位点 ID 对齐，再严格核对保存的六个字段，包括染色体、位置及区分大小写的 A1/A2。额外位点会忽略并计数；软件不会静默翻转等位基因或进行链互补。数值矩阵首先必须符合其自身配套 BIM 的位点顺序；无 BIM 模式必须保持编码来源声明一致。

多成员模型默认选择**所有成员等权平均（默认）**：每个成员使用自身冻结预处理，先还原目标原单位，再对预测等权平均。所有声明成员都必须完整且通过检查。**高级：指定单折**可以显式选择原始折，不能根据外层测试表现选折。单成员的模型间分歧为 0，这不意味着预测误差为 0。

身份设置决定评分资格，不影响没有表型时能否生成预测：

界面选项 / 记录状态	含义
来源关系不明（身份待核对） → identity_uncertain	默认选项。ID 文本相同或基因型相同，本身不能证明是同一个体。
与训练数据同一 ID 来源	将 ID 与保存成员中的训练、选择和固定图上下文比较，记录为 seen_training、seen_selection、seen_graph_context 或 confirmed_unseen。
已独立核实均为新个体 → confirmed_unseen	必须填写独立核实依据，例如材料登记和采样记录证明不与训练 / 选择个体重叠。

当新输入的基因型及含 ID 文件的哈希与原队列完全一致时，软件可以自动确认为同一来源；与此矛盾的“均为新个体”声明会被拒绝。固定队列的传导式个体图模型不能直接用于任意新个体。训练、选择、图上下文及身份不明记录分别报告；只有 confirmed_unseen 且有有限表型观测的记录进入 new_individual_metrics。

不提供表型时，输出预测而不产生观测准确性评价。提供表型时，缺失或未匹配观测不会删除预测，phenotype_match 分别记录 matched、missing_trait 或 unmatched_id；匹配上的非法观测会报错，应修正或明确声明为缺失。评分发生在冻结预测之后，新表型不参与训练、选折或参考特征构建。对原训练队列进行全成员平均预测并不等于 OOF；评价原队列时应使用保存的 OOF 结果。

16 常见问题与故障排查

先读错误码及其指向的文件或字段。保留失败目录：failure.json、cancelled.json、任务日志和未完成标记可以说明原因。不要删除未完成标记或编辑校验码，把失败运行伪装成完整结果。

现象	定位和处理
安装在下载阶段中断	查看最新 logs/setup-*.log 和 .status.json，确认失败在引导组件还是依赖。检查对应下载源的连通性与磁盘阈值，然后联网重跑相同环境的安装命令。首次安装不要加 -Offline。
启动提示环境不完整或已变化	在当前副本内重新运行对应环境的安装入口。移动文件夹、更改依赖/配置或混用环境都会使就绪记录失效；已安装环境损坏时使用 -Repair。

现象	定位和处理
GPU 不可用 / `E_DEVICE`	查看该 GPU 环境的 `logs/doctor-*.json`、驱动信息与实际计算失败原因。安装兼容环境或使用 CPU；同时明确修改项目和预测页的设备，程序不会静默替换设备。
缺少配套文件 / `E_FORMAT`	重新选择同一套 BED/BIM/FAM；矩阵输入则逐项核对分隔符、表头、行列布局、精确硬判定标记、编码方式与等位基因依据。改扩展名不等于转换格式。
没有匹配个体 / `E_DUPLICATE`	对照数据检查表中的完整 ID 字符串，保留前导零、清除意外空白，核对 ID 列名及双列/IID 模式，在数据源层面处理真实重复键。不能通过重新排列表型行“修复”匹配。
性状值非法 / `E_TRAIT`	查看 `invalid_traits.csv` 或检查报告定位行与性状，区分录入错误和真正缺失；确属缺失时声明精确缺失标记。不要把缺失表型统一改成 0 绕过检查。
“开始训练”不可点击 / `E_PREFLIGHT`	在最后一次修改后重新“运行前检查”，核对 JSON 字段、输入文件、网络维度或失效凭据。留一法还需先生成并确认真实任务规模。
网络错误 / `E_MODEL`、`E_PORT`	查看具体层与期望张量布局，核对卷积/池化后长度、注意力维度与头数整除关系、分支端口和回归输出数。筛选后的标记数可能不同于原始数；结合“形状与摘要”和预检查，参数存储量不等于总工作内存。
内存问题 / `E_MODEL_LIMIT`、`E_REFERENCE`	查看错误指出的存储/工作预算及资源报告。减小批大小可降低部分激活内存，也可能需要缩小网络、减少 token 或调整参考方案。核矩阵、KNN 参考和注意力有各自的上限；有依据地改配置并重新检查，不要仅盲目调大限制。
预测位点错误 / `E_MARKER`	对照错误标记及已经生成的 `marker_alignment.csv`。提供训练时原始全套位点及一致的元数据/等位基因编码；查询位点重排可以对齐，但不会自动修复等位基因翻转。无 BIM 矩阵还需核对编码来源声明。
模型加载失败 / `E_BUNDLE`	通过“选择…”指定完整、已完成的实验/模型包目录，不能只选权重文件。保留所有成员和状态文件；复制后校验失败，应重新取得完整副本，不能通过重新封存掩盖缺失或改动。
结果无法保存 / `E_IO`、`E_EXISTS`	核对具体路径和写权限，选择与输入及已有实验分开的新目录。GUI 自动附加唯一后缀；CLI 的 `--output` 不能是已存在目录。GUI 预测/导出位置使用选择器获得的绝对路径。
Pearson 无定义或很低	检查有限观测对数、预测/观测是否恒定、当前评价分区和原因字段。无定义不等于零。3 轮合成演示没有做准确性优化；不要依据保留测试成绩调参。
Excel 打开 CSV 乱码或 ID 前导零丢失	用显式导入方式选择 UTF-8，并将 ID 列设为文本。输出 CSV 使用无 BOM 的 UTF-8。保留原文件，避免表格软件静默改写来源 ID。
取消后的结果不能当模型打开	取消会保留未完成记录，不等同于断点续训。普通拟合应另选新输出重新运行；按性状任务的重试有专门兼容检查，不是通用训练恢复。

已安装 CPU 环境的诊断命令：

PowerShell

```
.\Start_GPNB_v1.cmd -Profile cpu -Doctor -Language zh_CN
```

此命令运行健康检查而不是打开主编辑界面。启动记录在 `logs/launch-*.log`，健康报告为 `logs/start-*.json`；工作进程请求与协议日志位于 `jobs/<id>`。科研输出位置见前文。反馈问题时提供错误码、相关参数和小型合成复现；分享日志前去掉私人路径、个人标识和真实输入数据。

17 可选 用命令复现小型示例

以下为**完成 CPU 安装后，在程序根目录执行的 PowerShell 命令**。直接使用本地 Python，无需激活环境。所有输出目录必须为新目录；重复演示时要一致地更换名称，包括预检凭据路径。`--lang` 是程序 CLI 参数；`-Language` 属于安装/启动入口，两者不要混用。

PowerShell

```
.\runtime\envs\cpu\Scripts\python.exe -m gpnb inspect .\examples\quickstart\project.json --scan --output .\runs\quickstart_audit --lang zh_CN
.\runtime\envs\cpu\Scripts\python.exe -m gpnb preview-split .\examples\quickstart\project.json --output .\runs\quickstart_split --lang zh_CN
.\runtime\envs\cpu\Scripts\python.exe -m gpnb preflight .\examples\quickstart\project.json --output .\runs\quickstart_preflight --lang zh_CN
.\runtime\envs\cpu\Scripts\python.exe -m gpnb train .\examples\quickstart\project.json --preflight-report .\runs\quickstart_preflight\summary.json --output .\runs\quickstart_train --lang zh_CN
.\runtime\envs\cpu\Scripts\python.exe -m gpnb save-model .\runs\quickstart_train --output .\runs\quickstart_model --lang zh_CN
.\runtime\envs\cpu\Scripts\python.exe -m gpnb export-plots .\runs\quickstart_train --output .\runs\quickstart_report --lang zh_CN
.\runtime\envs\cpu\Scripts\python.exe -m gpnb predict .\runs\quickstart_model --bed .\examples\quickstart\query\genotypes.bed --phenotype .\examples\quickstart\query\phenotype.csv --identity-relation confirmed_new --identity-note "Independently simulated query individuals with disjoint QRY identifiers." --dataset-id synthetic_query --output .\runs\quickstart_prediction --lang zh_CN
.\runtime\envs\cpu\Scripts\python.exe -m gpnb export .\runs\quickstart_train --include-data --output .\runs\quickstart_experiment --lang zh_CN
```

此处所有输入均为合成数据，因此使用 `--include-data`。真实实验应先明确接收者是否应获得输入数据。查看全部命令和参数：

PowerShell

```
.\runtime\envs\cpu\Scripts\python.exe -m gpnb --help
.\runtime\envs\cpu\Scripts\python.exe -m gpnb predict --help
```

实际子命令为 `save-model` 和 `export-plots`，不存在 `model-export` 或 `result-export`。GUI 训练要求有效预检凭据；CLI `train` 的 `--preflight-report` 是可选参数，本示例明确提供它。

18 网络组件与全部注册参数

当前纯净包注册了 **89 个组件**。本参考从该程序提取全部注册参数及“新增组件”默认值；模板或已有项目可以覆盖这些值。由上游层推导的输入宽度、通道数和尺寸，并非都需要用户手工填写。

GUI 会根据声明的输入和当前插入位置筛选选项。找不到某项时，打开为什么选项不可用？查看原因。参数处于允许范围，不等于组合后的形状兼容或内存足够；尺寸检查和运行前检查还会验证这些条件。

18.1 理解布局与端口

布局	不含 batch/个体轴的形状	含义
Vector	特征	每个个体一个平面向量。
Channels	通道 × 位置	一维卷积与池化布局。
Sequence	位置 × 宽度	循环层、token 和注意力布局。
Graph	位点 × 宽度	绑定到已配置位点图的特征。
Grid	通道 × 行 × 列	显式用户网格。
Mask	位置	序列位置的有效性信息。
Categorical	位点	用于嵌入的基因型/缺失类别。

`x` 是主要输入，`a`/`b` 是两个分支。`mask`、`query_mask`、`context_mask` 需要掩码；掩码 true 表示屏蔽/补齐位置，false 表示有效位置。`gate`、`weight` 需要向量。FeatureAffine 的 `condition` 端口必须是 Vector，而其主要 `x` 可为 Vector 或 Sequence。多输入组件的主布局列只是摘要，不能据此认为任意列出的布局组合都合法。

例如，ToChannels 把位点向量转为“一个通道、多个位点”；ToSequence 把每个位点放成一个标量序列位置；SingleToken 则把整个向量放入单个序列位置。这三者对应不同模型。Flatten 保留 batch 轴并合并其他维度；Reshape 必须保持每个个体的元素总数；Permute 只重排非 batch 轴。

表中格式为“`参数 = 新增时默认值`”，后接可选值或范围。`true`/`false` 对应复选状态。除非另有说明，范围包含端点；整数列表范围作用于各元素。非常大的上限只是校验边界，不是实际推荐值。

18.2 常用参数含义

参数类别	含义
out_features / out_channels / hidden_size	输出宽度、卷积通道数或内部学习宽度，增大通常增加存储和计算。
bias / affine / elementwise_affine	是否学习对应偏置或仿射缩放/平移参数。
p / dropout	训练时丢弃概率，预测使用评估模式。
kernel_size / kernel_h / kernel_w	各方向卷积/池化核覆盖的位置数。
stride / dilation / padding	窗口移动步长、核内间隔和边界补齐。
groups / num_groups	通道分组，仍须满足整除和最小尺寸要求。

参数类别	含义
eps	归一化数值稳定项；GIN 的 eps 则用于自身节点贡献权重。
momentum	运行统计更新参数；KerasBatchNorm1d 使用保留比例语义，与 BatchNorm1d 不同。
patch_size / embedding_dim / pad_tokens	每个 token 的位点数、token 宽度和额外补齐 token 数。
num_heads / heads	注意力头数，适用宽度须满足对应组件的整除要求。
max_score_elements / max_message_elements / max_elements	计算规模保护，单位为元素而非字节；实际检查也考虑 batch。
axis / axes / start / stop	拼接/切片轴或排列轴。Permute 使用非 batch 维度的零起始编号；Concat/Slice 使用 batch 后从 1 开始的张量轴。Slice 不包含 stop 位置。
mode / readout	把位置特征汇总或转为输出表示的方式。

18.3 全连接、激活与 Dropout

Linear 学习输入特征的加权组合，激活函数变换这些数值。Dropout 用于训练时正则化，预测时关闭。

组件	输入布局与端口	全部注册参数与新增默认值
`Linear`	Vector, Sequence, Graph 端口：`x`	`out_features = 32`; 整数 [1, 2147483647] `bias = true`
`Identity`	Vector, Channels, Sequence, Graph, Grid 端口：`x`	无可编辑参数
`ReLU`	Vector, Channels, Sequence, Graph, Grid 端口：`x`	无可编辑参数
`GELU`	Vector, Channels, Sequence, Graph, Grid 端口：`x`	无可编辑参数
`Tanh`	Vector, Channels, Sequence, Graph, Grid 端口：`x`	无可编辑参数
`Sigmoid`	Vector, Channels, Sequence, Graph, Grid 端口：`x`	无可编辑参数
`SiLU`	Vector, Channels, Sequence, Grid 端口：`x`	无可编辑参数
`ELU`	Vector, Channels, Sequence, Grid 端口：`x`	无可编辑参数

组件	输入布局与端口	全部注册参数与新增默认值
SELU	Vector, Channels, Sequence, Grid 端口：x	无可编辑参数
Softplus	Vector, Channels, Sequence, Grid 端口：x	无可编辑参数
Softsign	Vector, Channels, Sequence, Grid 端口：x	无可编辑参数
LeakyReLU	Vector, Channels, Sequence, Grid 端口：x	negative_slope = 0.01; [0, 1]
PReLU	Vector, Channels, Sequence 端口：x	init = 0.25; [0, 1]
Dropout	Vector, Channels, Sequence, Graph, Grid 端口：x	p = 0.2; [0, 1]
AlphaDropout	Vector, Channels, Sequence 端口：x	p = 0.2; [0, 1]
Dropout1d	Channels 端口：x	p = 0.2; [0, 1]

18.4 布局、切片与位点分组

这些组件改变一个个体内部的数据排列，不会把个体/batch 轴和特征轴交换。位点分组与位置采用文件顺序。

组件	输入布局与端口	全部注册参数与新增默认值
ToChannels	Vector 端口：x	无可编辑参数
ToSequence	Vector 端口：x	无可编辑参数
SingleToken	Vector 端口：x	无可编辑参数
MarkerChunk	Vector 端口：x	parts = 5; 整数 [1, 2147483647] index = 0; 整数 [0, 2147483647]
Pad1d	Channels 端口：x	left = 0; 整数 [0, 2147483647] right = 0; 整数 [0, 2147483647]
Flatten	Vector, Channels, Sequence, Grid 端口：x	无可编辑参数

组件	输入布局与端口	全部注册参数与新增默认值
Reshape	Vector, Channels, Sequence 端口：x	shape = [1,12]; 各整数元素 [1, 2147483647] layout = "Channels"; 可选："Vector", "Channels", "Sequence"
Permute	Channels, Sequence 端口：x	axes = [1,0]; 各整数元素 [0, 1] layout = "Sequence"; 可选："Channels", "Sequence"
Slice	Vector, Channels, Sequence 端口：x	axis = 1; 整数 [1, 2147483647] start = 0; 整数 [0, 2147483647] stop = 1; 整数 [1, 2147483647]

18.5 一维卷积与池化

卷积沿声明的位置顺序提取模式，池化缩减或汇总位置。LocallyConnected1d 使用位置特异权重，不是在全部位置共享一个卷积核。

组件	输入布局与端口	全部注册参数与新增默认值
Conv1d	Channels 端口：x	out_channels = 8; 整数 [1, 2147483647] kernel_size = 3; 整数 [1, 2147483647] stride = 1; 整数 [1, 2147483647] dilation = 1; 整数 [1, 2147483647] bias = true padding = 0; 整数 [0, 2147483647] groups = 1; 整数 [1, 2147483647]
DepthwiseSeparableConv1d	Channels 端口：x	out_channels = 8; 整数 [1, 2147483647] kernel_size = 3; 整数 [1, 2147483647] stride = 1; 整数 [1, 2147483647] dilation = 1; 整数 [1, 2147483647] bias = true padding = 0; 整数 [0, 2147483647]
CausalConv1d	Channels 端口：x	out_channels = 8; 整数 [1, 2147483647] kernel_size = 3; 整数 [1, 2147483647] stride = 1; 整数 [1, 2147483647] dilation = 1; 整数 [1, 2147483647] bias = true
LocallyConnected1d	Channels 端口：x	out_channels = 8; 整数 [1, 2147483647] kernel_size = 3; 整数 [1, 2147483647] stride = 1; 整数 [1, 2147483647] dilation = 1; 整数 [1, 2147483647] bias = true padding_left = 0; 整数 [0, 2147483647] padding_right = 0; 整数 [0, 2147483647] boundary = "file_order"; 可选："file_order"
MaxPool1d	Channels 端口：x	kernel_size = 2; 整数 [1, 2147483647] stride = 2; 整数 [1, 2147483647] padding = 0; 整数 [0, 2147483647] ceil_mode = false dilation = 1; 整数 [1, 2147483647]

组件	输入布局与端口	全部注册参数与新增默认值
AvgPool1d	Channels 端口：x	kernel_size = 2; 整数 [1, 2147483647] stride = 2; 整数 [1, 2147483647] padding = 0; 整数 [0, 2147483647] ceil_mode = false count_include_pad = true
AdaptiveAvgPool1d	Channels 端口：x	output_size = 1; 整数 [1, 2147483647]
AdaptiveMaxPool1d	Channels 端口：x	output_size = 1; 整数 [1, 2147483647]
GlobalPool1d	Channels 端口：x	mode = "mean"; 可选："mean", "sum", "max"

18.6 归一化

这些归一化层位于网络内部，与训练设置中的基因型/表型标准化不同；统计量及训练/预测行为取决于具体组件。

组件	输入布局与端口	全部注册参数与新增默认值
BatchNorm1d	Vector, Channels 端口：x	eps = 1e-05; [1e-12, 1.0] momentum = 0.1; [0, 1] affine = true track_running_stats = true
KerasBatchNorm1d	Vector, Channels 端口：x	eps = 0.001; [1e-12, 1.0] momentum = 0.99; [0, 1] affine = true
InstanceNorm1d	Channels 端口：x	eps = 1e-05; [1e-12, 1.0] momentum = 0.1; [0, 1] affine = true track_running_stats = false
GroupNorm	Channels 端口：x	num_groups = 1; 整数 [1, 2147483647] eps = 1e-05; [1e-12, 1.0] affine = true
LayerNorm	Vector, Channels, Sequence 端口：x	eps = 1e-05; [1e-12, 1.0] elementwise_affine = true
RMSNorm	Vector, Channels, Sequence 端口：x	eps = 1e-05; [1e-12, 1.0] elementwise_affine = true

18.7 循环层

循环层读取 Sequence。readout=sequence 保留全部位置，final_state 输出一个向量；双向处理会拼接两个方向，改变输出宽度。

组件	输入布局与端口	全部注册参数与新增默认值
RNN	Sequence 端口：x	hidden_size = 16; 整数 [1, 2147483647] num_layers = 1; 整数 [1, 2147483647] bias = true bidirectional = false dropout = 0.0; [0, 1] readout = "sequence"; 可选："sequence", "final_state" nonlinearity = "tanh"; 可选："tanh", "relu"
LSTM	Sequence 端口：x	hidden_size = 16; 整数 [1, 2147483647] num_layers = 1; 整数 [1, 2147483647] bias = true bidirectional = false dropout = 0.0; [0, 1] readout = "sequence"; 可选："sequence", "final_state"
GRU	Sequence 端口：x	hidden_size = 16; 整数 [1, 2147483647] num_layers = 1; 整数 [1, 2147483647] bias = true bidirectional = false dropout = 0.0; [0, 1] readout = "sequence"; 可选："sequence", "final_state"

18.8 基因型嵌入、token 与掩码

GenotypeEmbedding 对硬调用/缺失类别进行嵌入；Tokenize 将位点片段投影成序列；掩码标识有效位置，避免把补齐位置当成观测信号。

组件	输入布局与端口	全部注册参数与新增默认值
GenotypeEmbedding	Categorical 端口：x	embedding_dim = 8; 整数 [1, 2147483647]
Tokenize	Vector 端口：x	patch_size = 4; 整数 [1, 2147483647] pad_tokens = 0; 整数 [0, 2147483647] embedding_dim = 16; 整数 [1, 2147483647] bias = true
TokenMask	Vector 端口：x	patch_size = 4; 整数 [1, 2147483647] pad_tokens = 0; 整数 [0, 2147483647]
SequenceMask	Sequence 端口：x	valid_length = -1; 整数 [-1, 2147483647]
PositionEncoding	Sequence 端口：x	mode = "sinusoidal"; 可选："sinusoidal", "learned" max_length = 4096; 整数 [1, 2147483647]
ClassToken	Sequence 端口：x	无可编辑参数
PrependMask	Mask 端口：x	无可编辑参数
MaskedReadout	Sequence 端口：x, mask	mode = "mean"; 可选："mean", "sum", "max"
SequenceReadout	Sequence 端口：x	mode = "mean"; 可选："mean", "sum", "max", "first", "last"

组件	输入布局与端口	全部注册参数与新增默认值
ApplyMask	Sequence 端口：x, mask	无可编辑参数

18.9 注意力与序列混合

注意力组件需要连接表中声明的掩码端口，可先应用 token/注意力模板再编辑。分数矩阵元素数会随序列长度和 batch 快速增长。

组件	输入布局与端口	全部注册参数与新增默认值
SelfAttention	Sequence 端口：x, mask	num_heads = 4; 整数 [1, 2147483647] dropout = 0.0; [0, 1] bias = true causal = false max_score_elements = 8000000; 整数 [1, 2147483647]
ProjectedAttention	Sequence 端口：x, mask	hidden_size = 64; 整数 [1, 2147483647] scale_dim = 8; 整数 [1, 2147483647] dropout = 0.5; [0, 1] max_score_elements = 8000000; 整数 [1, 2147483647]
TransformerEncoder	Sequence 端口：x, mask	num_heads = 4; 整数 [1, 2147483647] dropout = 0.0; [0, 1] bias = true causal = false max_score_elements = 8000000; 整数 [1, 2147483647] num_layers = 1; 整数 [1, 2147483647] dim_feedforward = 64; 整数 [1, 2147483647] norm_first = true eps = 1e-05; [1e-12, 1.0] activation = "gelu"; 可选："gelu", "relu"
CrossAttention	Sequence 端口：query, context, query_mask, context_mask	num_heads = 4; 整数 [1, 2147483647] dropout = 0.0; [0, 1] bias = true max_score_elements = 8000000; 整数 [1, 2147483647]
AttentionPooling	Sequence 端口：x, mask	bias = true
MLPMixer	Sequence 端口：x, mask	token_hidden = 16; 整数 [1, 2147483647] channel_hidden = 32; 整数 [1, 2147483647] dropout = 0.0; [0, 1] eps = 1e-05; [1e-12, 1.0]

18.10 分支、门控与组合块

多端口组件使用显式分支连接。Add/Multiply 不会自动生成投影或对齐不匹配尺寸。DenseMoE 组合多个全连接专家，其专家数不是性状数。

组件	输入布局与端口	全部注册参数与新增默认值
`Add`	Vector, Channels, Sequence 端口：`a`, `b`	无可编辑参数
`Multiply`	Vector, Channels, Sequence 端口：`a`, `b`	无可编辑参数
`Concat`	Vector, Channels, Sequence 端口：`a`, `b`	`axis = 1`; 整数 [1, 2147483647]
`GatedAdd`	Vector, Sequence 端口：`a`, `b`	`bias = true`
`GatedMLP`	Vector, Sequence 端口：`x`	`hidden_size = 32`; 整数 [1, 2147483647] `bias = true` `dropout = 0.0`; [0, 1]
`SqueezeExcite1d`	Channels 端口：`x`	`hidden_size = 4`; 整数 [1, 2147483647]
`TCNBlock`	Channels 端口：`x`	`hidden_size = 8`; 整数 [1, 2147483647] `kernel_size = 3`; 整数 [1, 2147483647] `dilation = 1`; 整数 [1, 2147483647] `bias = true` `dropout = 0.0`; [0, 1]
`DenseMoE`	Vector 端口：`x`	`num_experts = 3`; 整数 [1, 128] `hidden_size = 16`; 整数 [1, 2147483647] `out_features = 8`; 整数 [1, 2147483647] `dropout = 0.0`; [0, 1]
`ChannelScale`	Channels 端口：`x`, `gate`	无可编辑参数
`ScaleByWeight`	Vector 端口：`x`, `weight`	无可编辑参数
`Softmax`	Vector, Channels, Sequence 端口：`x`	无可编辑参数
`OneMinus`	Vector, Channels, Sequence 端口：`x`	无可编辑参数
`FeatureAffine`	Vector, Sequence 端口：`x`, `condition`	`bias = true`

18.11 位点图与个体参考

GraphInput 绑定已经配置的位点拓扑，图消息传递层在位点上计算。ReferenceGraphSAGE 使用声明的个体参考协议，两者不是可互换的图类型。

组件	输入布局与端口	全部注册参数与新增默认值
GraphInput	Vector 端口：x	无可编辑参数
GCN	Graph 端口：x	out_features = 16; 整数 [1, 2147483647] bias = true max_message_elements = 8000000; 整数 [1, 2147483647]
GraphSAGE	Graph 端口：x	out_features = 16; 整数 [1, 2147483647] bias = true normalize = false max_message_elements = 8000000; 整数 [1, 2147483647]
GIN	Graph 端口：x	out_features = 16; 整数 [1, 2147483647] eps = 0.0; [-10.0, 10.0] train_eps = true max_message_elements = 8000000; 整数 [1, 2147483647]
GAT	Graph 端口：x	out_features = 8; 整数 [1, 2147483647] heads = 2; 整数 [1, 128] concat = true bias = true negative_slope = 0.2; [0.0, 1.0] dropout = 0.0; [0.0, 1.0] max_message_elements = 8000000; 整数 [1, 2147483647]
GraphReadout	Graph 端口：x	mode = "mean"; 可选："mean", "sum", "max", "attention"
ReferenceGraphSAGE	Vector 端口：x	hidden_size = 16; 整数 [1, 2147483647] num_layers = 2; 整数 [1, 8] bias = true max_message_elements = 8000000; 整数 [1, 2147483647]

18.12 显式二维网格

ToGrid 按文件顺序把特征放入用户指定网格。网格是计算布局，不是自动重建的染色体图或生物学图像；请核对补齐与尺寸。

组件	输入布局与端口	全部注册参数与新增默认值
ToGrid	Vector 端口：x	channels = 1; 整数 [1, 2147483647] rows = 0; 整数 [0, 2147483647] columns = 8; 整数 [1, 2147483647] layout = "file_order_user_grid"; 可选："file_order_user_grid" padding = "zero_end"; 可选："error", "zero_end" max_elements = 8000000; 整数 [1, 2147483647]

组件	输入布局与端口	全部注册参数与新增默认值
Conv2d	Grid 端口：x	kernel_h = 3; 整数 [1, 2147483647] kernel_w = 3; 整数 [1, 2147483647] stride_h = 1; 整数 [1, 2147483647] stride_w = 1; 整数 [1, 2147483647] padding_h = 0; 整数 [0, 2147483647] padding_w = 0; 整数 [0, 2147483647] out_channels = 8; 整数 [1, 2147483647] dilation_h = 1; 整数 [1, 2147483647] dilation_w = 1; 整数 [1, 2147483647] groups = 1; 整数 [1, 2147483647] bias = true max_elements = 8000000; 整数 [1, 2147483647]
MaxPool2d	Grid 端口：x	kernel_h = 3; 整数 [1, 2147483647] kernel_w = 3; 整数 [1, 2147483647] stride_h = 1; 整数 [1, 2147483647] stride_w = 1; 整数 [1, 2147483647] padding_h = 0; 整数 [0, 2147483647] padding_w = 0; 整数 [0, 2147483647] ceil_mode = false max_elements = 8000000; 整数 [1, 2147483647]
AvgPool2d	Grid 端口：x	kernel_h = 3; 整数 [1, 2147483647] kernel_w = 3; 整数 [1, 2147483647] stride_h = 1; 整数 [1, 2147483647] stride_w = 1; 整数 [1, 2147483647] padding_h = 0; 整数 [0, 2147483647] padding_w = 0; 整数 [0, 2147483647] ceil_mode = false max_elements = 8000000; 整数 [1, 2147483647] count_include_pad = true
AdaptiveAvgPool2d	Grid 端口：x	rows = 2; 整数 [1, 2147483647] columns = 2; 整数 [1, 2147483647] max_elements = 8000000; 整数 [1, 2147483647]
BatchNorm2d	Grid 端口：x	eps = 1e-05; [1e-12, 1.0] momentum = 0.1; [0.0, 1.0] affine = true
GridReadout	Grid 端口：x	mode = "mean"; 可选："mean", "sum", "max"

18.13 自相关与分解

这些组件实现 GPformer 适配中的明确运算，位置顺序采用输入顺序。AutoCorrelation 没有补齐掩码端口，其位置必须代表实际输入位置。

组件	输入布局与端口	全部注册参数与新增默认值
AutoCorrelation	Sequence 端口：x	num_heads = 4; 整数 [1, 2147483647] factor = 2.0; [0.1, 16.0] bias = true max_elements = 8000000; 整数 [1, 2147483647]

组件	输入布局与端口	全部注册参数与新增默认值
SeriesDecomposition	Sequence 端口：x	kernel_size = 25; 整数 [1, 1025] output = "residual"; 可选："residual", "trend"

18.14 辅助重建

ReconstructMarkers 产生声明的重建输出，需要显式分阶段目标；仅增加分支不会自动决定重建训练权重。

组件	输入布局与端口	全部注册参数与新增默认值
ReconstructMarkers	Vector 端口：x	bias = true

18.15 额外的形状与解释规则

- MarkerChunk 要求 index < parts <= 保留位点数，余数优先分配给前面的块；边界不会自动对应染色体或 LD 区块。
- Linear 作用于最后一维，不直接接受 Channels；需要显式转换布局或展平。
- 卷积分组数必须整除推导的输入和输出通道数；核、dilation、stride 和 padding 必须至少留下一个输出位置。一维普通池化的 padding 不超过 kernel 的一半。
- BatchNorm1d 要求 track_running_stats=true，以保存批次无关预测所需的运行统计。KerasBatchNorm1d 使用总体移动方差和 0.99 的保留式 momentum，是独立组件，不能直接与相同数字 momentum 的 BatchNorm1d 等同。普通 BatchNorm1d/2d 还会检查最后一个训练 batch。
- InstanceNorm1d 需要至少两个空间位置；GroupNorm 要求组数整除通道数，且每个个体每组至少两个元素。本实现的 LayerNorm/RMSNorm 归一化最后一维。
- 单层 RNN/LSTM/GRU 必须设 dropout=0，因为循环层的该参数作用于层间；如需其他位置的丢弃，请显式加入 Dropout。
- Tokenize 向上补齐到完整位点片段，再添加指定数量的补齐 token。TokenMask 需采用对应 patch/padding 设置。SequenceMask.valid_length=-1 表示全部位置有效。PositionEncoding 的序列长度不能超过 max_length；添加 ClassToken 后，使用带掩码的下游路径时也需相应 PrependMask。
- SelfAttention/Transformer/CrossAttention 的适用嵌入宽度须能被头数整除。ProjectedAttention 是独立的投影式操作，其 scale_dim 不是多头数；输入只有一个 token 时，注意力矩阵为 1 × 1。
- Add/Multiply 要求形状兼容；Concat 允许声明非 batch 轴，并检查其他维度。共享调用必须满足模块与形状兼容；复制层不会共享权重。
- ToGrid.rows=0 按特征数与通道/列数推导足够行数；zero_end 在末端补零。布局为 file_order_user_grid，不是生物学位置图。
- AutoCorrelation 使用每个个体的循环 FFT 相关及滞后聚合，没有补齐掩码输入；宽度须能被 num_heads 整除。SeriesDecomposition 要求奇数 kernel_size；trend 返回端点补齐后的移动均值，residual 返回减去该均值的残差。
- 图组件需要兼容且已配置的图/参考状态。参数少不意味着消息传递计算量小。注意力、图及网格上限是运行保护，不应不加判断地提高上限直到程序启动。

- AdaptiveMaxPool1d 存在严格确定性 CUDA 反向传播限制。正常训练路径会为该 CUDA 池化模型关闭严格确定性，除非显式要求严格模式；请查看生效设置及运行前检查报告。
- 单性状回归头必须为每个个体输出一个线性预测值，允许一个显式输出 Dropout，但不接受任意输出后操作；多目标输出宽度须与声明目标一致。

89 个组件是软件注册构件数，不是 89 种生物学预测方法，也不是 89 个经过独立论文实验验证的模型。已实现的组件仍可能不适合特定数据、布局、任务或资源上限。